

Control 2

Modelo Lineal de Probabilidad y Regresión Logística

SOC3070

Datos

Usaremos los datos de demanda de bicicletas de *Capital Bikeshare* (paquete ISLR2), los mismos que hemos usado en clases. La variable dependiente es “alta demanda”: un indicador de si el número de arriendos de una hora está en el 25 % superior (percentil 75) de la distribución.

```
library(ISLR2)

bikedata <- as.data.frame(Bikeshare)

# umbral de "alta demanda": top 25% de las horas (percentil 75 de bikers)
p75 <- quantile(bikedata$bikers, 0.75)
bikedata$high_demand <- as.integer(bikedata$bikers > p75)
```

Usaremos dos predictores: `temp` (temperatura normalizada, entre 0 y 1) y `hum` (humedad normalizada, entre 0 y 1).

Parte 1: Modelo Lineal de Probabilidad (LPM)

Ajusta el siguiente LPM: $\text{alta_demanda}_i = \beta_0 + \beta_1 \text{temp}_i + \beta_2 \text{hum}_i + e_i$.

1a) Interpreta el coeficiente del primer predictor (`temp`).

1b) Calcula la probabilidad predicha para la siguiente combinación de predictores: `temp = 0.1`, `hum = 0.9`. Brevemente, ¿qué representan estos valores?

Parte 2: Regresión logística (logit)

Ajusta ahora el mismo modelo, pero vía regresión logística: $\text{logit}(\mathbb{P}(\text{alta demanda}_i = 1)) = \beta_0 + \beta_1 \text{temp}_i + \beta_2 \text{hum}_i$.

2a) Calcula la probabilidad predicha para la misma combinación arbitraria de predictores.

2b) Explica por qué difieren tanto las predicciones del LPM y el logit.

Rúbrica

Cada pregunta (1a, 1b, 2a, 2b) se evalúa de 1 a 7. Nota final: promedio de las 4 preguntas.

R como calculadora

```
beta1 <- 2
exp(1 + beta1 * 10)

1 + 2 * 3
exp(1)
log(10)
1 / (1 + exp(-1))
```