

Control 2

Modelo Lineal de Probabilidad y Regresión Logística

SOC3070

Datos

Usaremos los datos de demanda de bicicletas de *Capital Bikeshare* (paquete ISLR2), los mismos que hemos usado en clases. La variable dependiente es “alta demanda”: un indicador de si el número de arriendos de una hora está en el 25 % superior (percentil 75) de la distribución.

```
library(ISLR2)

bikedata <- as.data.frame(Bikeshare)

# umbral de "alta demanda": top 25% de las horas (percentil 75 de bikers)
p75 <- quantile(bikedata$bikers, 0.75)
bikedata$high_demand <- as.integer(bikedata$bikers > p75)
```

Usaremos dos predictores: `temp` (temperatura normalizada, entre 0 y 1) y `hum` (humedad normalizada, entre 0 y 1).

Parte 1: Modelo Lineal de Probabilidad (LPM)

Ajustamos el siguiente LPM: $\text{alta_demanda}_i = \beta_0 + \beta_1 \text{temp}_i + \beta_2 \text{hum}_i + e_i$.

```
lpm <- lm(high_demand ~ temp + hum, data = bikedata)
summary(lpm)
```

Call:

```
lm(formula = high_demand ~ temp + hum, data = bikedata)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.756	-0.266	-0.123	0.140	1.154

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1429	0.0183	7.81	0.0000000000000063 ***
temp	0.7703	0.0215	35.84	< 0.0000000000000002 ***
hum	-0.4199	0.0217	-19.38	< 0.0000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.395 on 8642 degrees of freedom

Multiple R-squared: 0.166, Adjusted R-squared: 0.166

F-statistic: 859 on 2 and 8642 DF, p-value: <0.0000000000000002

Pregunta 1a) Interpreta el coeficiente del primer predictor (temp).

Respuesta: $\hat{\beta}_1 \approx 0.770$. En un LPM el coeficiente es directamente el efecto marginal sobre la probabilidad predicha, ya que $\mathbb{E}(y_i | x) = \mathbb{P}(y_i = 1 | x)$ es una función lineal de los predictores. Por tanto, manteniendo **hum** constante, un aumento de una unidad en la temperatura normalizada (es decir, pasar de la hora más fría a la más calurosa observada) se asocia a un aumento de 0.770 (77 puntos porcentuales) en la probabilidad predicha de alta demanda. Al ser un modelo lineal, este efecto se asume constante a lo largo de todo el rango de **temp**, sin importar el nivel de humedad ni el propio nivel de **temp**.

Pregunta 1b) Calcula la probabilidad predicha para la siguiente combinación de predictores: temp = 0.1, hum = 0.9. Brevemente, ¿qué representan estos valores?

Respuesta: Usando los coeficientes de la regresión ($\hat{\beta}_0 = 0.143$, $\hat{\beta}_1 = 0.770$, $\hat{\beta}_2 = -0.420$), calculamos la predicción “a mano”, con R como calculadora:

```
0.1429 + 0.7703 * 0.1 - 0.4199 * 0.9
```

```
[1] -0.158
```

Alternativamente, podemos usar el comando `predict()`:

```
nueva_obs <- data.frame(temp = 0.1, hum = 0.9)
predict(lpm, newdata = nueva_obs)
```

```
1
-0.158
```

$\text{temp} = 0.1$ y $\text{hum} = 0.9$ representan una hora fría (cercana al mínimo de temperatura observado) y muy húmeda (cercana al máximo de humedad observado); es decir, una hora poco propicia para que la gente arriende bicicletas. Para esta combinación, el LPM predice $\hat{p} = -0.158$, es decir, -15.8 %. Esta es una probabilidad fuera del rango $[0, 1]$ y por tanto no tiene sentido, a pesar de que ni $\text{temp} = 0.1$ ni $\text{hum} = 0.9$ están fuera del rango observado de cada variable por separado (temp va de 0.02 a 0.96 y hum de 0 a 1). El problema no es extrapolar fuera de los datos, sino que el LPM en sí mismo no está acotado a $[0, 1]$: es simplemente una recta (plano), y nada impide que combinaciones de predictores —incluso dentro de rango— produzcan valores ajustados negativos o mayores que 1.

Parte 2: Regresión logística (logit)

Ajustamos ahora el mismo modelo, pero vía regresión logística: $\text{logit}(\mathbb{P}(\text{alta demanda}_i = 1)) = \beta_0 + \beta_1 \text{temp}_i + \beta_2 \text{hum}_i$.

```
logit <- glm(high_demand ~ temp + hum, data = bikedata, family = binomial(link = "logit"))
summary(logit)
```

Call:

```
glm(formula = high_demand ~ temp + hum, family = binomial(link = "logit"),
    data = bikedata)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.059	0.125	-16.4	<0.0000000000000002 ***
temp	4.635	0.153	30.3	<0.0000000000000002 ***
hum	-2.404	0.143	-16.8	<0.0000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 9711.2 on 8644 degrees of freedom
Residual deviance: 8221.7 on 8642 degrees of freedom
AIC: 8228

Number of Fisher Scoring iterations: 4

Pregunta 2a) Calcula la probabilidad predicha para la misma combinación arbitraria de predictores.

Respuesta: Para $\text{temp} = 0.1$ y $\text{hum} = 0.9$, el predictor lineal es

$$\hat{\eta} = \hat{\beta}_0 + \hat{\beta}_1 \times \text{temp} + \hat{\beta}_2 \times \text{hum} = -2.059 + 4.635 \times 0.1 - 2.404 \times 0.9 = -3.759,$$

y al pasar esto por la función logística inversa,

$$\hat{p} = \frac{e^{\hat{\eta}}}{1 + e^{\hat{\eta}}} = \frac{e^{-3.759}}{1 + e^{-3.759}} = 0.023.$$

Con R como calculadora:

```
eta_hat <- -2.059 + 4.635 * 0.1 - 2.404 * 0.9
eta_hat
```

```
[1] -3.759
```

```
p_hat <- exp(eta_hat) / (1 + exp(eta_hat))
p_hat
```

```
[1] 0.02277
```

Alternativamente, usando `predict()`:

```
eta_hat <- predict(logit, newdata = nueva_obs, type = "link") # eta = b0 + b1*temp + b2*hum
eta_hat
```

```
1
-3.759
```

```
p_hat <- exp(eta_hat) / (1 + exp(eta_hat)) # p_hat = e^eta / (1 + e^eta)
p_hat
```

```
1
0.02277
```

Es decir, 2.3 %. A diferencia del LPM, esta probabilidad cae dentro del rango $[0, 1]$.

Pregunta 2b) Explica por qué difieren tanto las predicciones del LPM y el logit.

Respuesta: Ambos modelos usan los mismos datos y los mismos dos predictores, pero difieren en la forma funcional que relacionan los predictores con p_i .

- El LPM modela p_i como una función lineal *sin restricciones* de los predictores: $p_i = \beta_0 + \beta_1 \text{temp}_i + \beta_2 \text{hum}_i$. Nada en esta ecuación impide que $\hat{p}_i$ caiga fuera de $[0, 1]$; para una combinación de predictores “extrema” (fría y húmeda, es decir, poco propicia para alta demanda) la recta simplemente sigue extrapolando linealmente hacia valores negativos.
- El logit, en cambio, modela el *log-odds* (η_i) como función lineal de los predictores, y luego transforma η_i a probabilidad mediante la función logística (sigmoide), que es asintótica a 0 y a 1. Por muy negativo que sea $\hat{\eta}$ (en este caso, -3.759), $\hat{p} = e^{\hat{\eta}} / (1 + e^{\hat{\eta}})$ nunca puede ser menor que 0 ni mayor que 1: la sigmoide “comprime” predicciones extremas hacia los bordes del intervalo $[0, 1]$ en vez de dejarlas escapar de él.

En otras palabras, para una combinación de predictores asociada a una probabilidad muy baja (o muy alta), el LPM sigue extrapolando linealmente y puede cruzar los límites lógicos de una probabilidad, mientras que el logit está garantizado, por su forma funcional, a entregar siempre una predicción entre 0 y 1. Esta es precisamente la motivación para preferir el logit por sobre el LPM al modelar variables dependientes binarias, especialmente cuando $\mathbb{P}(y = 1)$ está cerca de 0 o de 1.

Rúbrica

Cada pregunta (1a, 1b, 2a, 2b) se evalúa de 1 a 7. Nota final: promedio de las 4 preguntas.