

Control 3 (recuperativo)

Regresión Logística: Odds Ratios, Efectos Marginales y Predicciones

SOC3070

Datos

Usaremos los datos de los pasajeros del *Titanic* (`TitanicSurvival`, paquete `carData`). La variable dependiente es `sobrevive` (1 = sobrevivió, 0 = no sobrevivió) y los predictores son `sex` (`female` o `male`), `clase`, la clase del pasaje tratada como variable continua (1 = tercera, 2 = segunda, 3 = primera), y `age`, la edad en años. Eliminamos los pasajeros sin edad registrada.

```
#install.packages("pacman")
library(pacman)
p_load(carData, marginaleffects)

titanic <- TitanicSurvival
titanic$sobrevive <- as.integer(titanic$survived == "yes")
titanic$clase <- 4 - as.integer(titanic$passengerClass) # 1 = tercera, 2 = segunda, 3 = primera
titanic <- subset(titanic, !is.na(age))
nrow(titanic)
```

```
[1] 1046
```

Parte 1: Regresión logística

Pregunta 1) Ajusta el siguiente modelo logit y reporta sus resultados: $\text{logit}(P(\text{sobrevive}_i = 1)) = \beta_0 + \beta_1 \text{hombre}_i + \beta_2 \text{clase}_i + \beta_3 \text{edad}_i$, donde hombre_i es una variable dummy (referencia: mujer) y edad_i es la edad en años.

Parte 2: Interpretación

**Pregunta 2) Interpreta los coeficientes de `sex` y de `age` en términos de odds ratio.

Pregunta 3) Calcula e interpreta el efecto marginal promedio (AME) de `clase` y el de `age`, usando `marginaleffects::avg_slopes()`.

Parte 3: Predicciones

Pregunta 4) Calcula la probabilidad predicha de sobrevivir de una mujer de 30 años que viaja en tercera clase. Haz el cálculo directamente en R a partir de los coeficientes estimados y luego verifica tu respuesta con `predict(..., newdata = ..., type = "response")`.

Rúbrica

Cada pregunta (1, 2, 3, 4) se evalúa de 1 a 7. Nota final: promedio de las 4 preguntas.

Anexo: ejemplos de código

Ejemplos con otra base (Mroz, paquete `carData`): participación laboral de mujeres casadas (lfp: no/yes) según educación universitaria (wc: no/yes) y edad (age).

Ajustar una regresión logística y ver sus resultados:

```
ejemplo <- glm(lfp ~ wc + age, data = Mroz, family = binomial(link = "logit"))
summary(ejemplo)
```

Call:

```
glm(formula = lfp ~ wc + age, family = binomial(link = "logit"),
    data = Mroz)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.88880	0.40684	2.18	0.02891 *
wcyes	0.63291	0.17106	3.70	0.00022 ***
age	-0.01839	0.00926	-1.99	0.04709 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1029.7 on 752 degrees of freedom
Residual deviance: 1010.7 on 750 degrees of freedom
AIC: 1017

Number of Fisher Scoring iterations: 4

Probabilidad predicha para un caso nuevo (los nombres de las columnas y las categorías deben escribirse igual que en la base):

```
caso_ejemplo <- data.frame(wc = "yes", age = 40)
predict(ejemplo, newdata = caso_ejemplo, type = "response")
```

```
1
0.687
```

Efecto marginal promedio de una variable:

```
avg_slopes(ejemplo, variables = "age")
```

Estimate	Std. Error	z	Pr(> z)	S	2.5 %	97.5 %
-0.0044	0.00219	-2.01	0.0449	4.5	-0.0087	-0.000101

Term: age

Type: response

Comparison: dY/dX