

SOC3070 ANÁLISIS DE DATOS CATEGÓRICOS

Segundo Semestre 2026

Instructor:	Mauricio Bucca	Horario Clases:	Lunes B1 12:20-13:30
Email:	mebucca@uc.cl		Lunes B2 14:50-16:00
		Horario Consulta:	Lunes 14:30-15:30

Ayudantía:

- Ayudante: Elisa Tagle (elisa.tagle@uc.cl)
- Horario: Jueves 16:10 - 17:20

Páginas del curso:

- Canvas
- Repositorio Github: https://github.com/mebucca/cda_soc3070

Descripción: Este curso se centra en el estudio de métodos estadísticos para el análisis de datos categóricos, con especial énfasis en modelos de regresión para variables dependientes categóricas. Este tipo de modelos es particularmente importante dado que muchos fenómenos de interés para las ciencias sociales no se manifiestan de modo continuo sino binario (si/no), ordinal (alto/medio/bajo), nominal (candidatos A/B/C) o como recuento (números de contagios por covid-19). Cuando trabajamos con variables dependientes categóricas los modelos estándar de regresión lineal son, *por lo general*, inapropiados. En consecuencia, el curso cubrirá una amplia gama de métodos disponibles para modelar este tipo de datos, muchos de los cuales son miembros de la familia de *Modelos Lineales Generalizados* (GLM), tanto para uso explicativo como predictivo. La clase tiene como objetivo desarrollar los conocimientos y habilidades necesarias para que los estudiantes apliquen estas herramientas en su propia investigación empírica, tanto aplicada o académica.

Resultados esperados: Al completar este curso *satisfactoriamente* se espera que los estudiantes sean capaces de:

- Entender los fundamentos estadísticos y matemáticos de los principales modelos para el análisis de datos categóricos.
- Implementar estos métodos en el software estadístico **R**.
- Interpretar sustantivamente los resultados de estos métodos, tanto en contextos explicativos como predictivos.

- Manipular matemáticamente los resultados de estos métodos para producir "cantidades de interés".

Prerequisitos sugeridos:

- Un curso de introducción a la estadística de nivel pregrado.
- Un curso de introducción al análisis de regresión de nivel pregrado.
- Familiaridad con el software estadístico R

Software: Las clases y evaluaciones del curso involucrarán el uso del software estadístico R. El contenido expositivo del curso, ayudantías y tareas se desarrollará exclusivamente en R. El código que acompaña cada clase será puesto a disposición de los estudiantes en el repositorio del curso, junto con material de nivelación matemática (pre-cálculo, cálculo y fundamentos de probabilidad) y una plantilla de Quarto para la escritura de tareas y trabajos.

Contenidos:

I. Probabilidad y fundamentos

1. Variables aleatorias y distribuciones discretas
2. Momentos, estimación MLE y funciones de pérdida

II. Modelos para datos categóricos -- uso explicativo

3. Modelo Lineal (Estándar y de Probabilidad)
4. Modelos Lineales Generalizados (GLM)
5. Regresión Logística (binomial y multinomial)
6. Regresión Poisson

III. Bridge: causalidad y predicción

7. Causalidad y asociación
8. Predicción: sesgo-varianza, overfitting, cross-validation

IV. Modelos para datos categóricos -- uso predictivo

9. Clasificadores logísticos (binomial y multinomial)
10. Regularización: Ridge & Lasso
11. Árboles de Regresión, Random Forests, Gradient Boosting
12. Redes Neuronales y un "flavor" de LLMs

Evaluaciones: 6 Tareas en horario de ayudantía (10.083% cada una) y elaboración/presentación de un póster científico en grupos de 2 integrantes (35%).

Actividad	Tema
Tarea 1	Nivelación matemática -- hasta Variables Aleatorias y Dist. Discretas
Tarea 2	LPM y teoría regresión logística
Tarea 3	Aplicación regresión logística
Tarea 4	Regresión multinomial
Tarea 5	Regresión Poisson
Tarea 6	Aplicación clasificación -- hasta Clasificador Log. Multinomial
Sesión de pósters	Presentación/trabajo final

Bibliografía: El curso es auto-contenido y no considera un texto obligatorio. No obstante, se recomiendan los siguientes libros como textos de consulta.

- Agresti, Alan. (1996). Introduction to Categorical data Analysis. Second Edition. Wiley Series.
- Gelman, A. y Hill, J. (2007). Data Analysis Using Regression and Multilevel/ Hierarchical Models. Cambridge University Press.
- Bilder, Christopher R., and Thomas M. Loughin (2014). Analysis of categorical data with R. CRC Press [Disponible online por medio de Biblioteca UC].

Políticas del curso:

- **Asistencia:** La asistencia regular a clases es importante, esperada, pero no obligatoria.
- **Entregas:** Las tareas y el póster final deben ser entregados a más tardar el día indicado en el calendario del curso, a la hora señalada.
- **Email:** Escribir primariamente para coordinar reunión en el horario de consulta. Incluir SOC3070 en el asunto del correo. Respondo correos una vez al día (en la mañana), de lunes a viernes.
- **Honestidad Académica:** El desconocimiento de la política de honestidad académica de la universidad - incluyendo el uso de IA - no es una explicación razonable para su incumplimiento.
- **Uso de IA:** Este curso permite el uso ético y transparente de herramientas de inteligencia artificial generativa, únicamente como herramienta de estudio o apoyo en la escritura de código. El estudiantado deberá declarar explícitamente en los anexos de cada tarea qué herramientas fueron utilizadas, con qué propósito y, si se

solicita, compartir los comandos o prompts empleados. El uso de IA no exime a los y las estudiantes de dominar plenamente el contenido de sus trabajos. Para verificar esto, en la clase posterior a la entrega de cualquier tarea, un estudiante será seleccionado al azar para explicar oralmente frente a la clase el procedimiento seguido en alguna de sus respuestas. En base a esta exposición, su nota podrá ser reconsiderada. El uso no autorizado o no declarado será considerado una falta a la integridad académica.

Calendario del curso: Clases los días Lunes, bloques 12:20-13:30 (B1) y 14:50-16:00 (B2). Calendario ajustado al Calendario de Actividades Académicas y Estudiantiles UC 2026: inicio de clases 2do semestre miércoles 5 de agosto (primer lunes lectivo: 10 de agosto), receso de docencia semana del 14 de septiembre, feriado Encuentro de Dos Mundos el 12 de octubre, y finalización de clases el 27 de noviembre (último lunes lectivo: 23 de noviembre).

I. Teoría de la Probabilidad y Fundamentos del Curso

Día	Mes	Bloque	Contenido
10	Agosto	B1	Presentación del curso
10	Agosto	B2	Variables Aleatorias y Distribuciones Discretas
17	Agosto	B1	Momentos
17	Agosto	B2	Estimación, MLE y Funciones de Pérdida

II. Modelos para datos categóricos -- uso explicativo

Día	Mes	Bloque	Contenido
24	Agosto	B1	Modelo Lineal Estándar
24	Agosto	B2	Modelo Lineal de Probabilidad
31	Agosto	B1	Modelos Lineales Generalizados
31	Agosto	B2	Regresión Logística -- estructura teórica y estimación
7	Septiembre	B1 & B2	Regresión Logística -- interpretación de parámetros
14	Septiembre	--	NO HAY CLASES (Receso de docencia UC)
21	Septiembre	B1 & B2	Regresión Logística -- inferencia estadística
28	Septiembre	B1	Regresión Log. Multinomial -- estructura teórica y estimación
28	Septiembre	B2	Regresión Log. Multinomial -- interpretación de parámetros
5	Octubre	B1	Regresión Poisson -- estructura teórica y estimación
5	Octubre	B2	Regresión Poisson -- interpretación de parámetros y extensiones
12	Octubre	--	NO HAY CLASES (Feriado: Encuentro de Dos Mundos)

III. Bridge: causalidad, asociación y predicción

Día	Mes	Bloque	Contenido
19	Octubre	B1	Causalidad y Asociación
19	Octubre	B2	Predicción (sesgo-varianza, overfitting, cross-validation)

IV. Modelos para datos categóricos -- uso predictivo

Día	Mes	Bloque	Contenido
26	Octubre	B1	Clasificador Logístico Binomial
26	Octubre	B2	Clasificador Logístico Multinomial
2	Noviembre	B1 & B2	Regularización: Ridge & Lasso
9	Noviembre	B1	Árboles de Regresión y Random Forests
9	Noviembre	B2	Gradient Boosting
16	Noviembre	B1	Introducción a Redes Neuronales
16	Noviembre	B2	Un "Flavor" de LLMs (usando Regresión Logística)
23	Noviembre	--	Sesión de Posters (trabajo final)

Recursos computacionales:

- En el repositorio del curso de *procesamiento avanzado de datos en R* se encuentra material para aprender **R** desde cero:
https://mebucca.github.io/dar_soc4001/.
- Material de nivelación matemática (pre-cálculo, cálculo, fundamentos de probabilidad) disponible en el repositorio del curso.
- Plantilla de **Quarto** para la escritura de tareas y trabajos disponible en el repositorio del curso.