SOC3070 Análisis de Datos Categóricos

Tarea corta 6

Ponderación: 5% de la nota final del curso. Entrega: Desde el momento de entrega, los estudiantes tienen 1 semana exacta de plazo para completar esta tarea.

Figure 1: NO

Problema:

En esta tarea usarás los datos de una encuesta realizada por FLACSO/Chile en Abril y Mayo de 1988 sobre intención de voto en el plebiscito de 1989, junto con otras variables socio-demográficas.

```r
datos_chile <- datos_chile %>% mutate(vote = case_when(vote=="Y" ~ 0, vote=="N" ~ 1))
datos_chile %>% glimpse()
```

```
## Rows: 2,700
## Columns: 8
## $ region     <fct> N, N, N, N, N, N, N, N, N, N, N, N, N, N, N, N, N, N, N, N,...
## $ population <int> 175000, 175000, 175000, 175000, 175000, 175000, 175000, ...
## $ sex        <fct> M, M, F, F, F, F, M, F, F, M, M, M, F, F, M, M, F, M, M,...
## $ age        <int> 65, 29, 38, 49, 23, 28, 26, 24, 41, 41, 64, 19, 27, 46, ...
## $ education  <fct> P, PS, P, P, S, P, PS, S, P, P, P, S, PS, S, PS, S, PS, ...
## $ income     <int> 35000, 7500, 15000, 35000, 35000, 7500, 35000, 15000, 15...
## $ statusquo  <dbl> 1.00820, -1.29617, 1.23072, -1.03163, -1.10496, -1.04685...
## $ vote       <dbl> 0, 1, 0, 1, 1, 1, 1, 1, NA, 1, 0, NA, 0, 0, NA, NA, 1, N...
```

En particular, trabajarás con el siguiente modelo de regresión logística que estima la probabilidad de votar NO en función de los ingresos, género y el apoyo al status-quo (valores más altos indican mayor apoyo al régimen de Pinochet).

```r
mymodel <- glm(vote ~ income  + sex*statusquo, family=binomial, data = datos_chile )
summary(mymodel)
```

```
##
## Call:
## glm(formula = vote ~ income + sex * statusquo, family = binomial,
##     data = datos_chile)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.8454  -0.1965   0.1516   0.2754   3.2390
##
## Coefficients:
##                  Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -8.026e-01  1.761e-01  -4.556 5.21e-06 ***
## income          6.251e-06  2.416e-06   2.588  0.00966 **
## sexM            6.506e-01  2.067e-01   3.147  0.00165 **
## statusquo      -3.252e+00  2.153e-01 -15.101  < 2e-16 ***
## sexM:statusquo  5.507e-02  2.900e-01   0.190  0.84940
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 2368.68  on 1708  degrees of freedom
## Residual deviance:  719.63  on 1704  degrees of freedom
##   (991 observations deleted due to missingness)
## AIC: 729.63
##
## Number of Fisher Scoring iterations: 6
```

1. Calcula el ratio de las odds de votar NO entre un hombre y una mujer con igual nivel de apoyo al status-quo

Dada la ecuación de regresión, las odds de votar NO están dadas por:

$$\frac{p_i}{1-p_i} = e^{\beta_{\text{income}}\text{income}} e^{\beta_{\text{sexM}}} e^{\beta_{\text{sq}}\text{sq}} e^{\beta_{\text{sexM*sq}}\text{sexM*sq}}$$

Por tanto, el ratio de las odds de votar NO entre un hombre y una mujer con igual nivel de apoyo al status-quo es:

$$OR = e^{\beta_{\text{sexM}}} e^{\beta_{\text{sexM*sq}}\text{sq}}$$

2. Usa el delta method para calcular el error estándar de la odds ratio referida en la pregunta 1.

$$SE_{g(\hat{\beta})} = g^{'}(\beta) \cdot SE_{\hat{\beta}}$$

En nuestro caso, dado que la OR de interés es una función de dos coeficientes, el delta method requiere:

- Calcular no sólo la derivada $g^{'}(\beta)$ con respecto a un coeficiente, sino la derivada de la transformación $g(\beta)$ con respecto a cada coeficiente involucrado. Esta información se almacena en una matriz llamada "gradiente", denotada como $\nabla g(\beta)$.
- Considerar no sólo la varianza de los coeficientes en cuestión, sino también su covarianza. En la práctica esto significa que, en vez del error estándard de un coeficiente, usaremos la matriz de varianza-covarianza para los coeficientes involucrados, denotada como Σ.

En particular:

- $g(\beta) = e^{\beta_{\text{sexM}}} e^{\beta_{\text{sexM*sq}}\text{sq}}$
- La gradiente $\nabla g(\beta)$ será calculada internamente por la función `deltamethod()`.
- La matriz varianza-covarianza del modelo Σ la podemos extraer de la siguiente manera:

```
vcov = vcov(mymodel)
```

Con estos elementos podemos usar la función `msm::deltamethod()` para calcular el error estándar de nuestra OR de interés. Para realizar el calculo fijaremos `statusquo` en dos valores distintos: -1 y 1.

```
# coeficientes de interés
coefs <- c(mymodel$coefficients["sexM"], mymodel$coefficients["sexM:statusquo"])

# gradiente calculada manualmente (sólo para chequear resultado)

grad1 <- c(exp(coefs[1])*exp(-1*coefs[2]),-1*exp(coefs[1])*exp(-1*coefs[2]))
grad2 <- c(exp(coefs[1])*exp(1*coefs[2]),1*exp(coefs[1])*exp(1*coefs[2]))

# formula con transformación de coeficientes

g1 <- formula( ~ exp(x1)*exp(-1*x2))
g2 <- formula( ~ exp(x1)*exp(1*x2))

# matriz de varianza convarianza

vcov_sex_sexsq = vcov(mymodel)[c("sexM","sexM:statusquo"),c("sexM","sexM:statusquo")]

deltamethod(g1, coefs, vcov_sex_sexsq)
```

```
## [1] 0.564011
```

```r
deltamethod(g2, coefs, vcov_sex_sexsq)
```

```
## [1] 0.8025103
```

```r
# manualmente:
sqrt(grad1 %*% vcov_sex_sexsq %*% grad1)
```

```
##          [,1]
## [1,] 0.564011
```

```r
sqrt(grad2 %*% vcov_sex_sexsq %*% grad2)
```

```
##           [,1]
## [1,] 0.8025103
```

3. Calcula el efecto marginal de la variable "statusquo" para hombres y mujeres (por separado), fijando ingresos y apoyo al status-quo a sus respectivos valores medianos (en la muestra completa).

```r
median_income = median(datos_chile$income, na.rm = T)
median_sq = median(datos_chile$statusquo, na.rm = T)

beta_sq_F = mymodel$coefficients["statusquo"]
beta_sq_M = mymodel$coefficients["statusquo"] + mymodel$coefficients["sexM:statusquo"]

grid <- datos_chile %>% data_grid(sex,income=median_income, statusquo = median_sq, .model=mymodel)
newx <- grid %>% mutate(logit = predict(mymodel, newdata = grid), p_hat = 1/(1 + exp(-logit))) %>%
  mutate(beta_sq = if_else(sex=="F",beta_sq_F,beta_sq_M)) %>%
  mutate(marginal_effect = beta_sq*p_hat*(1-p_hat))

print(newx %>% select(sex,income,statusquo,marginal_effect))
```

```
## # A tibble: 2 x 4
##   sex   income statusquo marginal_effect
##   <fct>  <dbl>     <dbl>           <dbl>
## 1 F      15000   -0.0456          -0.752
## 2 M      15000   -0.0456          -0.798
```

3. Usa el método de Bootstrap para crear un intervalo de confianza al 95% para la diferencia entre los efectos marginales para hombres y mujeres reportados en la pregunta 3.

```r
# Escribir una función que ejecute re-sampling y la estimación
bs_diff  <- function(x) {
  data_b  <- sample_n(datos_chile,size=nrow(datos_chile), replace=TRUE)
  logit_b <- glm(mymodel$formula, family=binomial(link="logit"), data=data_b)

  beta_sq_F_b = logit_b$coefficients["statusquo"]
  beta_sq_M_b = logit_b$coefficients["statusquo"] + logit_b$coefficients["sexM:statusquo"]
```

```r
  newx <- grid %>% mutate(logit = predict( logit_b, newdata = grid), p_hat = 1/(1 + exp(-logit))) %>%
    mutate(beta_sq = if_else(sex=="F",beta_sq_F_b,beta_sq_M_b)) %>%
    mutate(marginal_effect = beta_sq*p_hat*(1-p_hat))

  diff_b = newx$marginal_effect[1] - newx$marginal_effect[2]

  return(diff_FM_b = diff_b)
}

# Iterar función y almacenar resultados
nreps = 1000
diffs_bs <- replicate(nreps,bs_diff()) %>% as_tibble()

ci_diffs_bs <- quantile(diffs_bs$value, p=c(0.025,0.975)); ci_diffs_bs
```

```
##       2.5%      97.5%
## -0.1013104  0.1892767
```
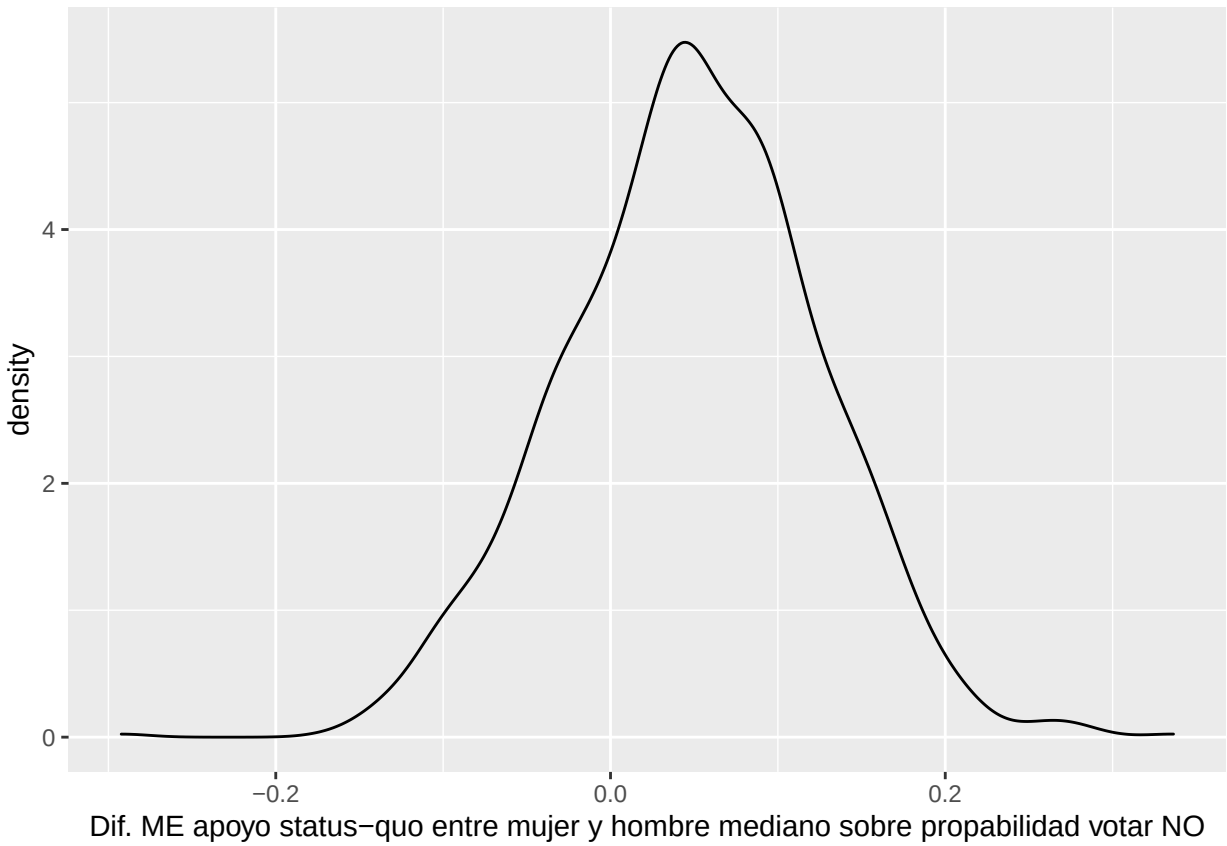
```r
diffs_bs  %>%  ggplot(aes(x=value)) + geom_density() + labs(x= "Dif. ME apoyo status-quo entre mujer y h
```