Trabajo Final

Maximiliano Arancibia y Tomás Barrientos

Índice

Bases de datos y paquetes **2**

1. Variables de interés **3**
1.1 Preparación base de datos 3

2. Pregunta de investigación **5**
2.1 Variables de control 5
2.1.1 Evaluación del color de piel del jugador, evaluador 1 (rater1) 5
2.1.2 Promedio de sesgo racial explícito en el país del árbitro (meanEXP) . . . 7
2.1.3 Término cuadrático Promedio de sesgo racial explícito en el país del árbitro 9

3. Estimación de modelos **9**
3.1 Tipo de modelo 12
3.2 Bondad de ajuste de los modelos 15

4. Interpretación de los resultados **17**

Bases de datos y paquetes

```
rm(list = ls())
library("pacman")
pacman::p_load(tinytex,
               texreg,
               tidyverse,
               dplyr,
               ggplot2,
               epiDisplay,
               kableExtra,
               modelr,
               geometry,
               emmeans,
               httr,
               stargazer,
               sjmisc,
               plyr,
               ggsci,
               sjPlot,
               margins,
               marginaleffects,
               readr,
               naniar,
               glm2)

# Cargamos la base de datos
path <- url("https://raw.githubusercontent.com/mebucca/cda_soc3070/master/homework/tf/redc
data_redcards <- read.csv(path)
```

1. Variables de interés

El interés del presente trabajo radica en las posibilidades de recibir una tarjeta roja y el país de pertenencia del club del jugador. Para abordar esto utilizaremos la variable número de tarjetas rojas que el árbitro en la diada jugador-árbitro le da al jugador. Esta está codificada de tal manera que 1 representa haber recibido una tarjeta roja por parte del arbitro y 0 no haber recibido una tarjeta roja por parte del arbitro.

Nuestra variable independiente refiere al país del equipo del jugador, la cual contempla las categorías Inglaterra, Alemania, Francia y España, siendo la primera la categoría de referencia. Adicionalmente utilizamos las variables de control evaluación del color de piel del jugador (evaluador 1), promedio de sesgo racial explícito en el país del árbitro y un término cuadrático de esta última variable.

1.1 Preparación base de datos

La base de datos fue trabajada de la siguiente manera, en la cual recodificamos el atributo 2 de la variable número de tarjetas rojas que el árbitro en la diada jugador-árbitro le da al jugador (`redcards`) para que tome el valor 1 y así poder medir la presencia (1) o ausencia (0) de tarjetas rojas. Adicionalmente, se eleminaron los NA de promedio de sesgo racial explícito en el país del árbitro (`meanEXP`), país del equipo del jugado (`leagueCountry`) y evaluación del color de piel del jugador, evaluador 1 (`rater1`). Posteriormente se creó el término cuadrático de la variable sesgo racial explícito en el país del árbitro multiplicándola por sí misma.

```
# Recodificación de variables
data_redcards$redCards2<- ifelse(data_redcards$redCards %in% c(1, 2), 1, data_redcards$red
data_redcards <- data_redcards[complete.cases(data_redcards$redCards2), ]

# Observamos la distribución de la variable dependiente
tab1(data_redcards$redCards2)
```

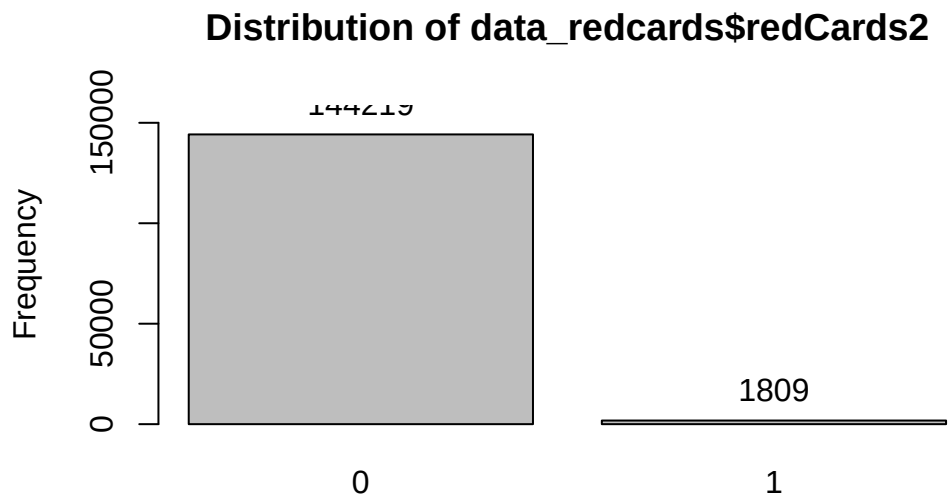


```
data_redcards$redCards2 :
        Frequency Percent Cum. percent
0          144219    98.8         98.8
1            1809     1.2        100.0
  Total    146028   100.0        100.0
```

```r
# Se eliminan los casos NA de cada variable
data_redcards <- data_redcards[complete.cases(data_redcards$meanExp), ]
data_redcards <- data_redcards[complete.cases(data_redcards$leagueCountry), ]
data_redcards <- data_redcards[complete.cases(data_redcards$rater1), ]

# Efecto cuadrático
data_redcards$meanExp2 <- data_redcards$meanExp*data_redcards$meanExp
```

Adicionalmente, se realizó primeramente un test Chi-Cuadrado para observar preliminarmente si hay independencia entre las variables de interés o, por el contrario, hay alguna dependencia que sea relevante de estudiar.

$$H0 : X^2 = 0$$

$$H1 : X^2 > 0$$

```
    Pearson's Chi-squared test

data:  data_redcards$redCards2 and data_redcards$leagueCountry
X-squared = 101.98, df = 3, p-value < 2.2e-16
```

A un 95% de nivel de confianza y con un valor-p equivalente a `2.2e-16`, se rechaza la hipótesis nula que indicaría independencia estadística entre las variables y, por tanto, podemos afirmar que hay una asociación estadísticamente significativa entre haber recibido una tarjeta roja y el país de pertenencia del equipo del jugador.

2. Pregunta de investigación

A partir de la pregunta de investigación de tipo dos mencionada por Auspurg y Brüderl (2021), a continuación se buscará responder a la interrogante: *¿el país de pertenencia del equipo de un jugador tiene un efecto sobre la probabilidad de que este reciba una tarjeta roja en algún partido jugado durante las divisiones masculinas europeas de la temporada 2012-2013?*

2.1 Variables de control

Como variables de control para nuestros modelos incluimos las variables evaluación del color de piel del jugador (evaluador 1), promedio de sesgo racial explícito en el país del árbitro y un término cuadrático de sesgo racial explícito en el país del árbitro, esto para capturar posibles explicaciones que escapen a la relación bivariada de nuestro modelo, estas son descritas a continuación.

2.1.1 Evaluación del color de piel del jugador, evaluador 1 (rater1)

Esta variable es una variable continua la cual fue construida a partir de la codificación realizada por evaluadores independientes que, observando la foto de un jugador, clasificaron a los participantes en una escala de 5 puntos que abarca desde "tez extremadamente clara" (0) hasta "tez muy oscura" (1), siendo "tez intermedia" (0.5) el valor central de la escala. Se utilizó la clasificación del evaluador 1, capturada por la variable `rater1`.

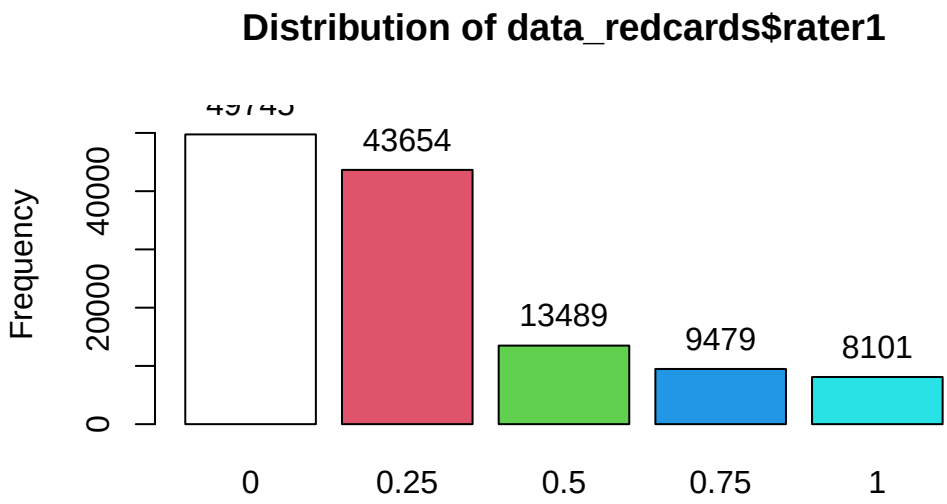


```
data_redcards$rater1 :
        Frequency Percent Cum. percent
0           49745    40.0         40.0
0.25        43654    35.1         75.0
0.5         13489    10.8         85.9
0.75         9479     7.6         93.5
1            8101     6.5        100.0
  Total    124468   100.0        100.0
```

Para examinar la pertinencia de incluir la variable al modelo realizamos un test de Chi-cuadrado para testear la asociación entre la variable dependiente (haber recibido una tarjeta roja) y la clasificación de la tonalidad de piel del jugador.

$$H0 : X^2 = 0$$

$$H1 : X^2 > 0$$

```
    Pearson's Chi-squared test

data:  data_redcards$redCards2 and data_redcards$rater1
X-squared = 14.291, df = 4, p-value = 0.006423
```

El resultado muestra que hay una asociación estadísticamente significativa, a un nivel de confianza del 95%, entre la variable Evaluación del color de piel del jugador y la variable dependiente, por lo que es pertinente incluirla en el modelo para controlar por `rater1`.

Sustantivamente, haría sentido controlar por la tonalidad de piel del jugador pues sería razonable esperar que aquellos jugadores de piel más oscura sean más propensos de recibir sanciones y tarjetas rojas por parte de los árbitros. Así, se controla y se distingue el efecto del país del equipo del jugador sobre la probabilidad de recibir tarjetas rojas respecto del efecto de la tonalidad de piel del mismo.

2.1.2 Promedio de sesgo racial explícito en el país del árbitro (meanEXP)

Esta variable corresponde a la puntuación media de prejuicios explícitos (mediante una prueba de termómetro racial) para el país de referencia, donde los valores más altos corresponden a mayores sentimientos de calidez hacia las personas blancos que hacia las personas negras. Esta variable toma valores desde el -1.38 hasta el 1.80 para los valores medios de la puntuación. Esta variable se comporta de la siguiente manera:

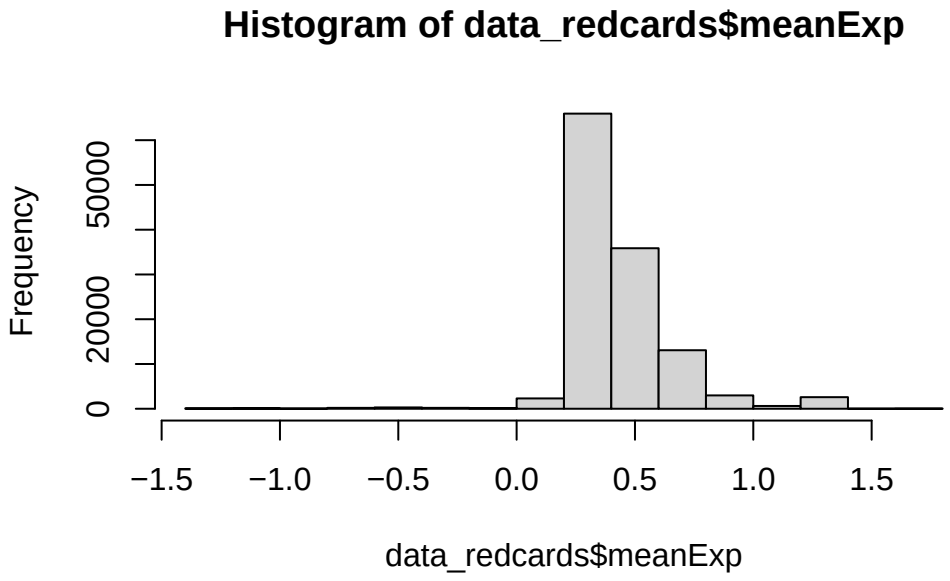

Adicionalmente realizamos un t-testo para comprobar si existe alguna diferencia estadísticamente significativa en el promedio del sesgo racial explícito para cada grupo de jugadores según si recibieron o no tarjeta roja.

$$H0 : \mu_{X_1} = \mu_{X_2}$$

$$H1 : \mu_{X_1} \neq \mu_{X_2}$$

```
    Welch Two Sample t-test

data:  meanExp by redCards2
t = 2.5133, df = 1643.8, p-value = 0.01206
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 0.002207702 0.017899942
sample estimates:
mean in group 0 mean in group 1
      0.4639238       0.4538700
```

El resultado de este test demuestra la pertinencia de la inclusión de la variable Promedio de sesgo racial explícito en el país del árbitro en tanto que el promedio de sesgo racial explícito es distinto entre quienes reciben una tarjeta roja respecto de quienes no reciben.

Sustantivamente, la pertinencia de incluir esta variable como variable de control remite a que se puede controlar por el sesgo racial que el árbitro podría poseer al haber sido socializado en su país de origen. Dado que ese país puede tener cierto sesgo transmitido al árbitro, se controla así por posibles prejucios del árbitro que luego se reflejen en una tendencia que posea en otorgarle tarjetas rojas a jugadores de piel oscura respecto de jugadores de piel clara. Asimismo, se prefirió omitir el sesgo racial implícito, pues esta última variable no posee necesariamente una manifestación pública que pueda expresarse, por ejemplo, en entregar una tarjeta roja (una sanción) a un jugador, comportamiento que sí puede verse reflejado en un sesgo racial explícito que supone la expresión pública de prejucios raciales

2.1.3 Término cuadrático Promedio de sesgo racial explícito en el país del árbitro

Finalmente, bajo el presupuesto de que el promedio del sesgo racial explícito en el país del árbitro no posee un comportamiento lineal, se incluirá un término cuadrático de dicha variable para observar cómo cambia el efecto ante el aumento de prejucios y sesgos promedio que posea el país del árbitro. En efecto, sería razonable pensar que el aumento de sesgos raciales promedio no posee un efecto constante sobre la probabilidad de entregar tarjetas rojas, sino que este efecto es más bien cuadrático, tal que el aumento promedio del sesgo racial en sus primeros valores tiene un efecto grande sobre la probabilidad de entregar una tarjeta roja al jugador, pero en la medida que el sesgo racial promedio aumenta, este efecto es cada vez menor.

Realizamos realizamos un t-testo para comprobar si existe alguna diferencia estadísticamente significativa en el promedio cuadrático del sesgo racial explícito para cada grupo de jugadores según si recibieron o no tarjeta roja.

$$H0 : \mu_{X_1} = \mu_{X_2}$$

$$H1 : \mu_{X_1} \neq \mu_{X_2}$$

```
    Welch Two Sample t-test

data:  meanExp2 by redCards2
t = 7.2242, df = 1653.6, p-value = 7.663e-13
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 0.02416153 0.04217117
sample estimates:
mean in group 0 mean in group 1
      0.2635762       0.2304098
```

El resultado de este test demuestra la pertinencia de la inclusión de la variable Promedio cuadrático del sesgo racial explícito en el país del árbitro en tanto existe una asociación estadísticamente significativa entre esta variable y la variable dependiente, esto siendo significativo a un nivel de confianza del 95%.

3. Estimación de modelos

A partir de la presentación de variables y la justificación de su inclusión, se estimarán distintos modelos para observar la pertinencia de incluir cada variable predictora, y sus comportamientos una vez que estas se relacionan entre sí.

A priori, el siguiente gráfico indica las Odds-Ratio del efecto de cada variable sobre las chances de recibir una tarjeta roja indicando el efecto de cada variable a un 95% de nivel de confianza.

```
plot_graficoOR <- tidy(m4, exponentiate = FALSE, conf.int = TRUE)  |>
  mutate_if(is.numeric, round, 4)

plot_graficoOR <- plot_graficoOR %>%
  mutate(term = case_when(
    term == "(Intercept)" ~ "Intercepto",
    term == "leagueCountryFrance" ~ "Francia",
    term == "leagueCountryGermany" ~ "Alemania",
    term == "leagueCountrySpain" ~ "España",
    term == "rater1" ~ "Tonalidad jugador",
    term == "meanExp" ~ "Sesgo racial explícito",
    term == "meanExp2" ~ "Sesgo racial explícito cuadrático",
    TRUE ~ term
  ))

plot_graficoOR %>%
  mutate(or=round(exp(estimate), 2)) %>%
  ggplot(aes(y = term, x = estimate, label = or)) +
  geom_point(aes(y = term, x=estimate), color= "blue", alpha = 0.5) +
  geom_errorbarh(aes(xmax = conf.high, xmin = conf.low, height = .12), color ="blue", alph
  geom_vline(xintercept =0, linetype = "dashed") +
  scale_shape_manual(values = c(0,2,19)) +
  geom_text(size = 3.5, nudge_x = 2,vjust = -0.25) +
  scale_x_continuous(limits=c(-5,5)) +
  theme_gray()+
  theme(legend.position = "bottom",
        plot.title = element_text(hjust = 0.5, size = 15),
        axis.title = element_text(size=10),
        axis.text.x = element_text(size=11),
        axis.text.y = element_text(size = 11),
        legend.text = element_text(size = 10),
        legend.title = element_text(face = "bold", size = 12)) +
  guides(pch=guide_legend(title="Patrones")) +
  ylab("") +
  xlab("") +
  ggtitle("Gráfico N°1: coeficientes de regresión con OR") +
 # scale_y_discrete(limits=rev) +
  scale_y_discrete(expand=c(0.05, 0),
                   limits = c("Intercepto",
```

```
                                "Francia",
                                "Alemania",
                                "España",
                                "Tonalidad jugador",
                                "Sesgo racial explícito",
                                "Sesgo racial explícito cuadrático"))
```

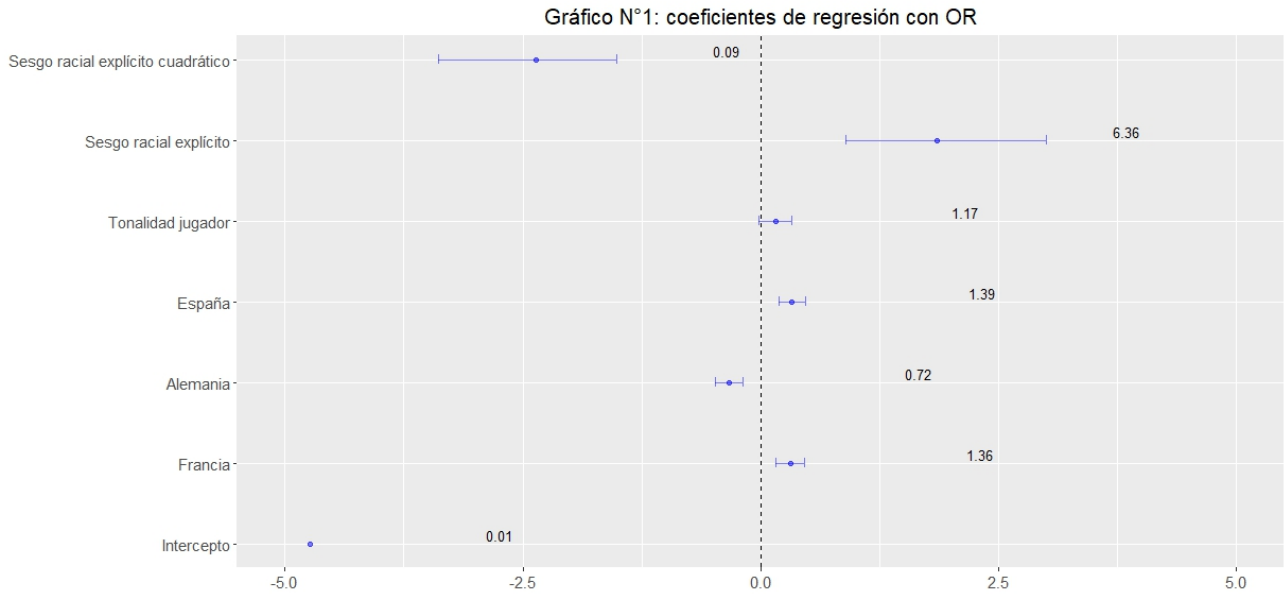

Como se puede observar en el gráfico N°1, a priori, en todas las variables —con excepción de la tonalidad del jugador— hay un efecto estadísticamente significativo distinto de 0 sobre las chances de un jugador de obtener una tarjeta roja. Concretamente, a un 95% de nivel de confianza, mientras que ser de España y Francia implica tener un efecto positivo respecto de pertenecer de Inglaterra sobre las chances de recibir una tarjeta roja, ser de Alemania vendría siendo la única categoría que se encuentra asociada con chances negativas respecto de Inglaterra de recibir tarjetas rojas.

De esta manera, preliminarmente y a nivel inferencial sí sería posible observar un efecto significativo entre pertenecer a un equipo de un determinado país europeo y las chances de recibir tarjetas rojas, pues los jugadores adscritos a equipos alemanes son quienes tienen menores probabilidades de recibir tarjetas rojas, caso contrario de los jugadores pertenecientes a clubes españoles y franceses.

3.1 Tipo de modelo

Siendo la variable dependiente un suceso dicotómico que representa el que un jugador haya recibido al menos una tarjeta roja en algún partido jugado en la temporada futbolística europea 2012-2013, esta variable debe pensarse como una binomial que es función del país de pertenencia del equipo de fútbol, controlando por la tonalidad de la piel y el efecto del sesgo racial explícito del país de origen del árbitro.

Siendo logit la función de enlace del modelo, el cual pertenece a la familia estadística binomial, la siguiente ecuación representa formalmente las estimaciones a realizar:

$$logit(redCards2_i) = ln(\frac{p_i}{1-p_i}) = \beta_0 + \beta_1 leagueCountry_i + \beta_2 rater1_i + \beta_3 meanExp_i + \beta_4 meanExp2_i$$

Donde la variable `redCards2` posee una distribución Bernoulli tal que:

$$redCards2_i \sim Bernoulli(p_i = \frac{e^{n_i}}{1+e^{n_i}})$$

```
# Modelo bivariado
m1 <- glm(redCards2 ~ leagueCountry,
          data = data_redcards,
          family = binomial(link = "logit"))

# Modelo multivariado (raza jugador)
m2 <- glm(redCards2 ~ leagueCountry + rater1,
          data = data_redcards,
          family = binomial(link = "logit"))

# Modelo multivariado (raza jugador y sesgo racial árbitro)
m3 <- glm(redCards2 ~ leagueCountry + rater1  + meanExp,
          data = data_redcards,
          family = binomial(link = "logit"))

# Modelo no restringido
m4 <- glm(redCards2 ~ leagueCountry + rater1 + meanExp + meanExp2,
          data = data_redcards,
          family = binomial(link = "logit"))
```

	Modelo 1	Modelo 2	Modelo 3	Modelo 4
(Intercept)	-4.4102^{***}	-4.4470^{***}	-4.2696^{***}	-4.7396^{***}
	(0.0490)	(0.0559)	(0.0768)	(0.1536)
leagueCountryFrance	0.3220^{***}	0.3091^{***}	0.2983^{***}	0.3098^{***}
	(0.0752)	(0.0758)	(0.0759)	(0.0759)
leagueCountryGermany	-0.3377^{***}	-0.3238^{***}	-0.3379^{***}	-0.3340^{***}
	(0.0733)	(0.0740)	(0.0742)	(0.0744)
leagueCountrySpain	0.2839^{***}	0.2909^{***}	0.3285^{***}	0.3282^{***}
	(0.0668)	(0.0670)	(0.0680)	(0.0696)
rater1		0.1213	0.1021	0.1536
		(0.0870)	(0.0872)	(0.0873)
meanExp			-0.3855^{***}	1.8501^{***}
			(0.1158)	(0.5370)
meanExp2				-2.3588^{***}
				(0.4774)
AIC	16711.5610	16711.6358	16702.7951	16645.9542
BIC	16750.4882	16760.2948	16761.1859	16714.0768
Log Likelihood	−8351.7805	−8350.8179	−8345.3975	−8315.9771
Deviance	16703.5610	16701.6358	16690.7951	16631.9542
Num. obs.	124468	124468	124468	124468

$^{***}p < 0.001$; $^{**}p < 0.01$; $^{*}p < 0.05$

Table 1: Statistical models

La tabla N°1 muestra los resultados de los modelos estimados. Fueron estimados cuatros modelos Logit, en donde el modelo 1 comprende únicamente la variable de interés leagueCountry, el modelo 2 incluye la variable de interés rater1, el modelo 3 incluye las variables independientes anteriores incluyendo meanExp y, finalmente, el modelo 4 comprende todas las variables independientes presentes en los modelos sumada al efecto cuadrático de meanExp.

A través de todos los modelos se puede apreciar que las log odds de nuestra variable de interés, leagueCountry, sobre las odds de recibir una tarjeta roja son estadísticamente significativas a un nivel de confianza del 99%. De esta manera, podemos afirmar que el leagueCountry, tiene un efecto sobre las odds de recibir una tarjeta roja, este efecto se mantiene relativamente estable en tanto varía decimalmente con la inclusión de las variables de control. Po otro lado, se parecía la variable de control rater1 no tiene significancia estadística en ninguno de los modelos en la que se le incluyo. Finalmente, en lo que respecta a la variable de control meanExp, se tiene un efecto estadísticamente significativo al 99% de confianza. Sin embargo, esta variable drásticamente su coeficiente al incluir el efecto cuadrático de la misma, siendo este efecto estadísticamente significativo al 99% de confianza. Esta evidencia sostiene que es pertinente incluir un término cuadrático de meanExp, en tanto no tiene una asociación lineal, sino que desde el valor -0.5 de su escala cambia el sentido del efecto sobre las log odds de

recibir una tarjeta roja.

```
b <- coef(m4)["meanExp2"]
ptoInfl <-  (-b)/(2*b)
print(paste0("Punto de inflexión término cuadrático: ",ptoInfl))
```

```
[1] "Punto de inflexión término cuadrático: -0.5"
```

3.2 Bondad de ajuste de los modelos

```
mlista <- list(m1, m2, m3, m4)
modelos <- c("Modelo 1",
                                  "Modelo 2",
                                  "Modelo 3",
                                  "Modelo 4")
AIC_values <- numeric(length(modelos))
BIC_values <- numeric(length(modelos))


mejorAIC <- NULL
mejorBIC <- NULL
min_AIC <- Inf
min_BIC <- Inf


for (i in seq_along(modelos)) {
  AIC_values[i] <- AIC(mlista[[i]])
  BIC_values[i] <- BIC(mlista[[i]])

  if (AIC_values[i] < min_AIC) {
    min_AIC <- AIC_values[i]
    mejorAIC <- modelos[i]
  }

  if (BIC_values[i] < min_BIC) {
    min_BIC <- BIC_values[i]
    mejorBIC <- modelos[i]
  }
}

resultados <- data.frame(Modelo = modelos, AIC = AIC_values, BIC = BIC_values)
print("Resultados modelos:")
```

```
[1] "Resultados modelos:"
```

```
print.data.frame(resultados)
```

```
  Modelo      AIC      BIC
```

```
1 Modelo 1 16711.56 16750.49
2 Modelo 2 16711.64 16760.29
3 Modelo 3 16702.80 16761.19
4 Modelo 4 16645.95 16714.08
```

```r
cat("\nMejor modelo según AIC:", mejorAIC, "\n")
```

```
Mejor modelo según AIC: Modelo 4
```

```r
cat("Mejor modelo según BIC:", mejorBIC, "\n")
```

```
Mejor modelo según BIC: Modelo 4
```

Al observar la bondad de ajuste de los modelos, podemos dar cuenta de que el modelo 4 es el que posee mejor ajuste, motivo por el cual se utiliza para analizar los datos y responder así la pregunta de investigación.

Concretamente, en el modelo 4 (modelo no restringido) se presenta el menor BIC y el menor AIC, por lo que las predicciones que realiza se ajustan mejor a la distribución de datos de las variables. Según las reglas de Raftery, cuando la diferencia entre el ajuste de ambos modelos supera los dos puntos, podemos establecer que hay diferencias significativas en el nivel de ajuste estos, lo que sí se cumple con el modelo 4. Es por esta razón que, para responder a la pregunta de investigación, se analizará el modelo 4 y la pertenencia de cierto país sobre la probabilidad de recibir una tarjeta roja por parte de un jugador, controlando por las variables asociadas a la raza del jugador como de los prejuicios raciales del país de origen del árbitro.

```r
aaanova <- anova(m1, m2, m3, m4)
print(aaanova)
```

```
Analysis of Deviance Table

Model 1: redCards2 ~ leagueCountry
Model 2: redCards2 ~ leagueCountry + rater1
Model 3: redCards2 ~ leagueCountry + rater1 + meanExp
Model 4: redCards2 ~ leagueCountry + rater1 + meanExp + meanExp2
  Resid. Df Resid. Dev Df Deviance
1    124464      16704
2    124463      16702  1    1.925
3    124462      16691  1   10.841
4    124461      16632  1   58.841
```

De hecho, si analizamos la devianza residual ocurre algo similar. Comparando cuánto se desvía cada modelo respecto de un modelo saturado en el cual hay se describe de mejor manera el ajuste de los datos en tanto que cada observación posee su propio parámetro, a mayor sea el valor de la devianza residual, peor ajuste posee el modelo y, en consecuencia, las predicciones son menos plausibles. En ese sentido, el modelo que posee menor devianza residual es el modelo 4, por lo que se puede esperar que, al compararlo con el modelo saturado, sea el modelo 4 el que haya que analizar pues es aquel que ofrece mayor plausibilidad de predicciones y estimaciones no sesgadas según la estructura de datos.

4. Interpretación de los resultados

Respecto al modelo 4, podemos afirmar que nuestra variable de interés leagueCountry tiene un efecto estadísticamente significativo en todas sus categorías. Sustantivamente, estas categorías nos indican, en el caso de Francia, que las log odds promedio de que a un jugador adscrito a un club francés le den tarjeta roja son de 0.31 en comparación con un jugador de Inglaterra, bajo los niveles de confianza convencionales y controlando por el resto de variables. De igual manera, las log odds de que a un jugador asociado a un equipo español le asignen una tarjeta roja son de 0.33 en comparación con un jugador inglés, habiendo significancia estadística bajo niveles convencionales de confianza, ceteris paribus.

Por otro lado, el efecto de las log odds presenta una asociación negativa para el caso de los jugadores adscritos a un equipo alemanes, por lo que en su caso las log odds de recibir una tarjeta roja son de –0.33 respecto de no recibirla en comparación con Inglaterra.

Los resultados anteriores indican que, a nivel general, el país al que pertenece el equipo de un jugador sí se relevante en torno a la probabilidad de recibir una tarjeta roja en alguna sesión de juego, en tanto que, en comparación con Inglaterra, aquellos jugadores adscritos a equipos franceses y españoles tienen mayores probabilidades de recibir una tarjeta roja, mientras que los equipos alemanes son los que tienen una menor probabilidad de recibir alguna sanción que implique que los retiren de algún partido. En referencia a la pregunta de investigación, podemos establecer que en la temporada de futbol masculino 2012-2013, entre los países de Europa sí hay un efecto entre la pertenencia de cada equipo a algún país con la probabilidad de recibir una tarjeta roja: los equipos alemanes son los que poseen la menor probabilidad de recibir alguna sanción de este tipo, mientras que los españoles son los que mayor probabilidad tienen de recibir una tarjeta roja. Lo anterior controlando tanto por la tonalidad de piel del jugador como sesgos raciales del país del árbitro que puedan reflejarse en el comportamiento del mismo, tal que los factores raciales tendrían un efecto separado y distinguido respecto del efecto de pertenencia de cada club a cierto país.

```r
# Generamos base de datos
data_futbol <- expand.grid(
```

```r
  leagueCountry = c("Spain", "France", "Germany", "England"),
  rater1 = mean(data_redcards$rater1),
  meanExp = mean(data_redcards$meanExp),
  meanExp2 = mean(data_redcards$meanExp2)
)

# Calculamos las probabilidades predichas del modelo
predict <- predict(m4,
                   newdata = data_futbol,
                   type = "response")

# Se adjuntan los valores predichos a la base de datos creada
data_futbol$predict <- predict

# Graficamos
ggplot(data_futbol, aes(x = leagueCountry,
                        y = predict,
                        color = leagueCountry)) +
  geom_line() +
  geom_point(size = 5) +
  labs(title = "Gráfico N°2: probabilidad predicha de obtener una tarjeta roja por país",
       x = "País",
       y = "Probabilidad predicha") +
  theme_minimal()
```

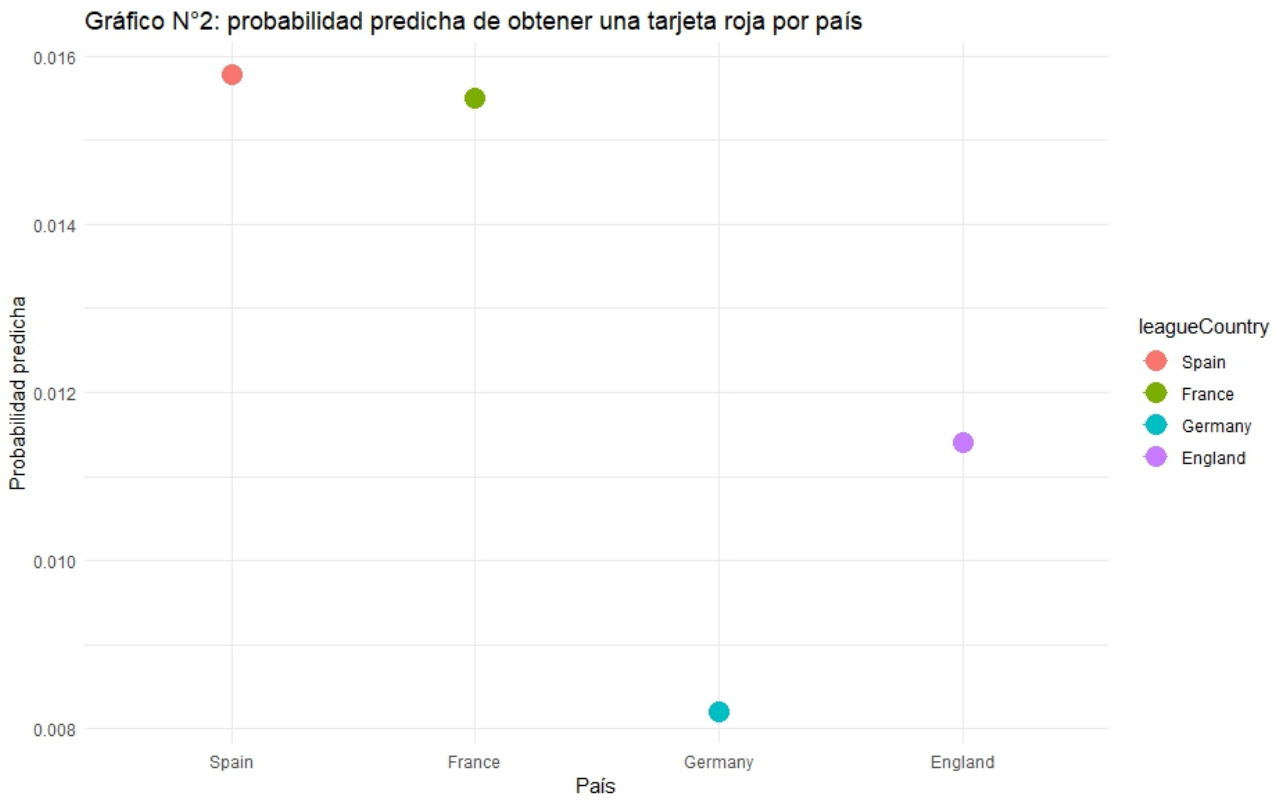

A partir del gráfico 2 se puede visualizar las probabilidades predichas de obtener una tarjeta roja por país del jugador. Podemos apreciar que España tiene las mayores probabilidades predichas de obtener una tarjeta roja, con una probabilidad del 1,57%. Este es seguido por Francia con una probabilidad predicha de obtener una tarjeta roja de 1,55%. En tercer lugar, tenemos a Inglaterra con una probabilidad predicha de obtener tarjetas rojas de 1,14%. Y, finalmente, tenemos la probabilidad predicha de 0,81% de obtener tarjetas rojas para los jugadores alemanes. Si bien, las probabilidades predichas de obtener tarjetas rojas nunca superan el 1,6% se puede apreciar que para Alemania las probabilidades predichas de obtener una tarjeta roja son sustancialmente más bajas que para España, Francia e Inglaterra.