# Trabajo Final - Análisis de Datos Categóricos

Alarcón, Chackiel, Echeverría - 2023

## El efecto de un buen equipo de Fútbol en la cantidad de goles de los jugadores de las ligas de primera división inglesa y española.

### Datos

En el presente trabajo se utilizan los datos generados por una empresa de estadísticas deportivas y fotos de perfil de todos los futbolistas (N = 2053) que jugaron en las primeras divisiones masculinas de Inglaterra, Alemania, Francia y España en la temporada 2012-2013. La base de datos contiene 146028 díadas (pares) de árbitro-jugador. La siguiente lista describe en detalle las variables de la base de datos que se mantienen para el trabajo:

- `playerShort`: identificador único del jugador
- `player`: nombre del jugador
- `club`: equipo del jugador
- `leagueCountry`: país del equipo del jugador (England, Germany, France, Spain)
- `birthday`: fecha de nacimiento del jugador
- `height`: altura del jugador (en cm)
- `weight`: peso del jugador (en kg)
- `position`: posición en la que juega el jugador
- `games`: número de partidos en los que participó la diada jugador-árbitro
- `goals`: número goles marcado por el jugador en la diada jugador-árbitro

### Importación y exploración de la base de datos

Se hace un subset de la base de datos original, para dejar solamente las variables de interés del trabajo. Además, se excluyen los países con los que no se trabajará, Alemania y Francia, dejando solo a los países Inglaterra y España. Se escoge dejar a estos dos últimos países por tener equipos más conocidos para el equipo de investigación y en general en el contexto local chileno, junto con que en la temporada 2012-2013 estaban en un auge del fútbol europeo.

```
path <- url("https://raw.githubusercontent.com/mebucca/cda_soc3070/master/homework/tf/redc
data_redcards <- read.csv(path)
data_redcards %>% glimpse()

data_redcard <- dplyr::select(data_redcards, playerShort, player, club,
                              leagueCountry, birthday, height, weight,
                              position, games, goals)

england_spain <- subset(data_redcard, leagueCountry %in% c("England", "Spain"))

table(england_spain$club)

# Dejamos los 20 equipos que jugaron en la Premier League (Inglaterra)
# y en LaLiga (España) en la temporada 2012-2013
premierleague_laliga <- england_spain %>%
  filter(club == "Manchester United" | club == "Manchester City" | club == "Chelsea FC" |
           club == "Arsenal FC" | club == "Tottenham Hotspur" | club == "Everton FC" |
           club == "Liverpool FC" | club == "West Bromwich Albion" | club == "West Ham Uni
           club == "Norwich City" | club == "Fulham FC" | club == "Stoke City" |
           club == "Southampton FC" | club == "Aston Villa" | club == "Newcastle United" |
           club == "Sunderland AFC" | club == "Wigan Athletic" | club == "Reading FC" |
           club == "Queens Park Rangers" | club == "Athletic Bilbao" | club == "Atlético M
           club == "CA Osasuna" | club == "FC Barcelona" | club == "Getafe CF" |
           club == "Granada CF" | club == "Levante UD" | club == "Málaga CF" |
           club == "Rayo Vallecano" | club == "Real Betis" | club == "Celta Vigo" |
           club == "Deportivo La Coruña" | club == "Espanyol Barcelona" | club == "RCD Mal
           club == "Real Madrid" | club == "Real Sociedad" | club == "Real Valladolid" |
           club == "Real Zaragoza" | club == "Sevilla FC" | club == "Valencia CF")

# Nos queda una base de datos con 75374 observaciones y 10 variables
```

Luego, queremos que en nuestra base, cada fila sea un sólo jugador, para ver la cantidad de goles hechas por cada jugador a lo largo de la temporada, independiente del árbitro con el que anotó el gol. Es decir, dejar atrás la noción de base long y diadas, para pasar a una en lógica

de formato wide. **Se reducen las filas que duplican a los jugadores, a una sola fila que represente a cada jugador**. Se debe seguir la misma lógica con la variable games, que indica el número de partidos en que participó una diada. Al agrupar también por el jugador, se estarían sumando todos los partidos del jugador, generando una variable con el recuento total.

Asimismo, se hace un análisis de los casos perdidos que resultan en la base final, que contiene 973 observaciones, es decir, ese número de jugadores de los clubs seleccionados de Inglaterra y España, y 12 variables en total, ya que se generó la nueva variable de interés "goles_totales".

- Se identifica que la variable de altura del jugador tiene 9 casos perdidos; la variable del peso del jugador tiene 45 casos perdidos; y la variable de la posición del jugador tiene 159 casos perdidos. Para poder estimar modelos que sean comparables entre sí, en términos de los criterios de información que dan cuenta de la bondad del ajuste del modelo, se decide dejar los casos completos en la base, y por lo tanto eliminar a los jugadores que no tienen información en dichas variables.
- Por lo tanto, **el N final de nuestra muestra es igual a 790 jugadores** de primera división en la temporada 2012-2013, considerando a jugadores tanto de Inglaterra como de España.

```r
library(dplyr)
# Agrupar por el jugador y suma de sus goles (goals)
jugadores_pl <- premierleague_laliga %>%
  group_by(player) %>%
  summarise(goles_totales = sum(goals))

# Agrupar por el jugador y suma de sus partidos (games)
jugadores_pl_games <- premierleague_laliga %>%
  group_by(player) %>%
  summarise(games_totales = sum(games))

# Fusionar los data frames
# original "premierleague_laliga". Además, se reducen las filas que duplican
# los jugadores, a una sola fila que represente a cada jugador.
base_finall <- left_join(premierleague_laliga, jugadores_pl, by = "player") %>%
  distinct(player, .keep_all = TRUE)
base_final <- left_join(base_finall, jugadores_pl_games, by = "player") %>%
  distinct(player, .keep_all = TRUE)

# Ahora, la variable dependiente de interés es "goles_totales" y no "goals",
# ya que ya no se distingue cuantos goles hizo cada jugador con un árbitro
# en específico, sino la cantidad que hizo durante toda la temporada
```

```r
# En la base de datos quedan 973 observaciones y 12 variables

# Generamos matriz para analizar los casos perdidos dentro de las variables.
matriz_perdidos <- matrix(0, nrow = ncol(base_final), ncol = 1)
colnames(matriz_perdidos) <- "CasosPerdidos"

for (i in 1:ncol(base_final)) {
  matriz_perdidos[i, 1] <- sum(is.na(base_final[, i]))
}

# Agregamos los nombres de las variables como filas en la matriz
rownames(matriz_perdidos) <- colnames(base_final)

# Observamos la cantidad de casos con datos completos: 790
nrow(na.omit(base_final))
```

```
[1] 790
```

```r
# Se dejan solo los casos completos
base_final <- base_final[complete.cases(base_final), ]
```

**NOTA METODOLÓGICA**: Los partidos totales y goles totales por jugador quedarán con valores muy extremos con esta recodificación, asumimos que la razón es que hay más de un árbitro que contabilizó un partido junto al jugador y los goles del jugador en un mismo partido. Sin embargo, no tenemos cómo saber si están los datos exactamente de 4 árbitros por partido, debido a que al intentar probarlo con determinados jugadores no fue factible al estar anonimizados los árbitros. Tampoco sabemos si se debe a que la base está mal codificada. No tenemos ninguna información que nos permita acercarnos a una versión más realista de los partidos en que participó un jugador a lo largo de la temporada (que, teóricamente, debería ser máximo 38), ni de la cantidad de goles que realmente anotaron durante la temporada, por lo que nuestras variables son un proxy que extrema la realidad. No tenemos la fecha ni algún identificador del partido, tampoco un manual ni información sobre cómo se construyó la base, y podríamos haber inventado algún re-escalamiento de la variable, pero preferimos dejarlas así las dos siguiendo la misma lógica de agrupamiento, asumiento que ambas variables están aumentadas en una misma lógica, lo que permitiría tener resultados fidedignos a pesar de los problemas en términos de la relación entre variables que se planteará. Esto, simplemente, siguiendo la sugerencia del ayudante de agrupar mediante la función "summarise" de "dplyr".

### Pregunta de investigación y variables de interés

La pregunta de esta investigación que se busca responder es ***¿la calidad del equipo en el que está un jugador afecta en la cantidad de goles que este logra anotar a lo largo de la temporada?***

El foco está en la relación entre jugar en un equipo mejor o peor de la primera división de Inglaterra o España, y la cantidad de goles hechos por el jugador en la temporada 2012-2013. La intuición detrás de la idea es que un jugador puede meter más goles estando en un buen equipo que estando en un mal equipo. Es decir, un buen jugador de un club de buena calidad, estadísticamente podrá meter más goles que un jugador bueno con las mismas características que juega en un club de peor calidad.

Puede que parezca bastante obvia la relación, al pensar que un equipo también es bueno porque sus jugadores meten más goles. Pero, la verdad es que detrás de un equipo de mejor calidad no solo hay jugadores más competitivos en términos de goles, sino también más recursos monetarios, trayectorias, entrenadores, entre otras variables no observadas. Para que la relación no pueda ser bidireccional, y haya una direccionalidad clara, se define que un buen club, definido según su rendimiento en la temporada anterior a la de la base (t=2011-2012) predice la cantidad de goles que un jugador puede hacer en la temporada siguiente (t+1=2012-2013). Además, los puntos de la liga, que nos permiten asignar categorías de buen o mal club, se obtienen por partidos ganados (3 puntos por ganar) y empatados (1 punto por empatar), habiendo 0 puntos al perder, y por ende no tiene que ver explícitamente con cantidad de goles. Solo cuando un equipo está empatado en puntos con otro, se define qué equipo va más arriba en la tabla según cuál tiene mejor diferencia de goles.

Nuestras **variables de interés** son la cantidad de goles marcados por los jugadores durante toda la temporada, como variable dependiente, y la pertenencia del jugador a un buen equipo, como variable independiente. Para utilizar nuestra variable independiente de interés, se recodificará de tal manera que indique si el equipo de los jugadores es de los que serán catalogados como "buenos" o de los que serán considerados malos o peores de la primera división de cada uno de los países.

- La ***variable dependiente*** es el **número de goles** (`goles_totales`) hechos por los jugadores durante la temporada 2012-2013. Esta es de **recuento**, en que los números son enteros, por lo que es una variable discreta, y el recuento es la manifestación de una variable aleatoria, porque si repitiéramos la temporada bajo las mismas condiciones, la cantidad total de goles por jugador sería otro número. La distribución de una variable de recuento como esta se asume que es Poisson. A continuación, se observa la distribución de la variable mediante un histograma y se exploran los *outliers*.
  - En primer lugar, el mínimo de goles hechos por un jugador es 0 y el **máximo recuento (valor esperado) es 420 goles** en toda la temporada, siendo la mediana 14, la moda 0, y la media 30 goles. Aquello se puede obtener tratando a la variable

como continua numérica, para efectos de tener los estadísticos descriptivos, pero en general en el trabajo se trata como una de recuento discreta.

- En segundo lugar, la distribución de goles está **sesgada** hacia la derecha, o hay una asimetría positiva, en tanto hay una mayor concentración en los valores más bajos de cantidad de goles de un jugador en la temporada, pero un par de casos extremos se escapan en la cola derecha de la distribución. Esto hace pensar que puede ser más útil asumir una distribución binomial negativa que una Poisson, porque el conteo está muy sesgado en concentrarse hacia los ceros; pero, se omite usar un poisson negativo por criterios de simplicidad de modelar y conocimiento de las autoras de la investigación en el marco del curso.

- En tercer lugar, notamos que muchos registros de goles no tienen sentido sustantivo. Desde la base de datos original hay problemas, y está mal codificada, por ejemplo, porque plantea que Ronaldo hizo 21 goles en un solo partido, y Messi 23, lo que es imposible. En la base final que estamos usando, aparece que Messi metió 387 goles en total, y, si bien fue el máximo goleador de la Primera División Española esa temporada, lo hizo con 46 goles (*Primera División de España 2012-13*, 2023). Por el lado de Inglaterra, el máximo recuento de goles fue hecho por Robin van Persie, con 26 goles, y en la base de datos aparece que su recuento es 236 (*Premier League 2012-13*, 2023). En concreto, vemos que hay una distribución rara: hay muchos valores extremos que no tienen sentido sustantivo y no se condicen con la realidad. Se pensó generar un criterio de exclusión y sacar de la base de datos a los casos más extremos, pero al ver quiénes son, efectivamente calza con los goaleadores máximos de las ligas, entonces sería alterar la distribución y podría perjudicar las relaciones que queremos modelar. Por ende, se asume el riesgo de tener una variable de recuento "falsa" en términos de que está mal codificada la cantidad de goles, y el recuento discreto no es representativo de la realidad, pero de todas maneras se justifica usar la variable porque sirve para dar cuenta de las tendencias reales que pueden existir.

```r
# Exploración de variable dependiente:
summary(base_final$goles_totales)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
   0.00    3.00   14.00   30.76   37.00  420.00 
```

```r
DescTools::Mode(base_final$goles_totales)
```

```
[1] 0
attr(,"freq")
[1] 102
```

```
# Histograma de la variable dependiente:
# hist(base_final$goles_totales, freq = TRUE,
 #    breaks = seq(min(base_final$goles_totales), max(base_final$goles_totales),
 #                 length.out = 20), col = "lightblue",
 #    main = "Histograma de goles hechos por los jugadores")


# Observar los 10 casos más extremos del recuento de goles
# Ordenar el conjunto de datos por la variable de interés de forma descendente
# datos_ordenados <- base_final[order(-base_final$goles_totales), ]
# Seleccionar los 10 casos con los valores más altos
# top_10_casos <- head(datos_ordenados, 10)
# Mostrar los resultados
#print(top_10_casos)
#print(top_10_casos$goles_totales)
```

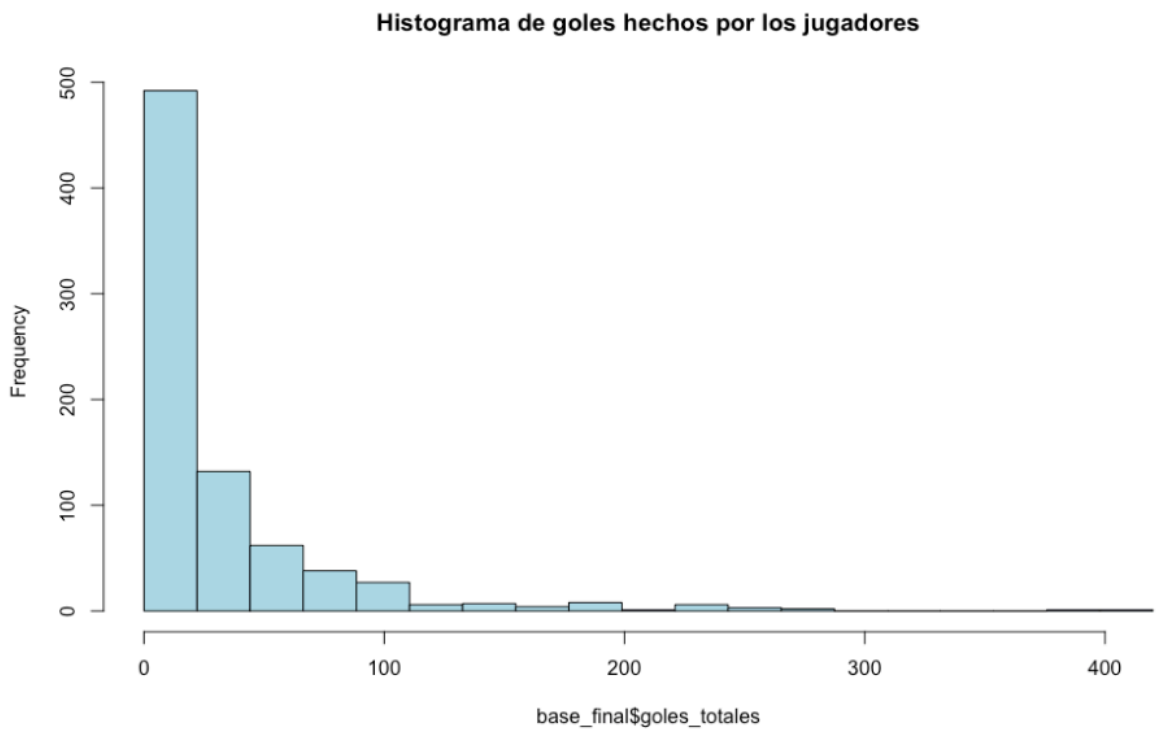

| player <chr> | club <chr> | leagueCountry <chr> | birthday <chr> | height <int> | weight <int> | position <chr> | games <int> | goals <int> | goles_totales <int> | games_totales <int> |
|---|---|---|---|---|---|---|---|---|---|---|
| Cristiano Ronaldo | Real Madrid | Spain | 05.02.1985 | 185 | 80 | Left Winger | 3 | 0 | 420 | 650 |
| Lionel Messi | FC Barcelona | Spain | 24.06.1987 | 169 | 67 | Right Winger | 1 | 1 | 387 | 498 |
| David Villa | FC Barcelona | Spain | 03.12.1981 | 175 | 69 | Center Forward | 1 | 1 | 281 | 554 |
| Wayne Rooney | Manchester United | England | 24.10.1985 | 178 | 78 | Center Forward | 1 | 0 | 271 | 608 |
| Frank Lampard | Chelsea FC | England | 20.06.1978 | 183 | 77 | Center Midfielder | 1 | 1 | 265 | 914 |
| Dimitar Berbatov | Fulham FC | England | 30.01.1981 | 188 | 79 | Center Forward | 5 | 3 | 258 | 580 |
| Michael Owen | Stoke City | England | 14.12.1979 | 173 | 70 | Center Forward | 2 | 1 | 244 | 531 |
| Fernando Torres | Chelsea FC | England | 20.03.1984 | 183 | 70 | Center Forward | 1 | 1 | 238 | 596 |
| Robin van Persie | Manchester United | England | 06.08.1983 | 183 | 71 | Right Winger | 3 | 1 | 236 | 509 |
| Luis Suárez | Liverpool FC | England | 24.01.1987 | 182 | 81 | Right Winger | 2 | 1 | 234 | 398 |

10 rows | 3–13 of 12 columns

- La ***variable independiente*** es la **calidad del club** o equipo (`buen_club`). Esta variable es categórica binaria, es decir, **dummy**. Los valores que puede tomar son 1 cuando el club es bueno y 0 cuando el club es malo. Los equipos catalogados como "buenos" son aquellos en las primeras posiciones de la temporada anterior de la liga de fútbol de primera división, es decir, los que tuvieron puntajes más altos en los campeonatos de la Premier League de Inglaterra y LaLiga de España en la temporada 2011-2012. Así, esta variable independiente cumple con ser temporalmente previa a la variable dependiente, y el rendimiento en la temporada anterior es lo que define si el equipo llega como "bueno" o "malo" a la temporada del análisis presente.

  - La justificación yace en que históricamente siempre son aproximadamente los mismos siete equipos que se pelean el primer lugar de la liga inglesa, e incluso menos equipos los que se pelean la liga española. El **punto de corte** se hace incluyendo la posición en la tabla del último equipo clasificado a una copa europea internacional. En el caso de la liga inglesa, el Liverpool, con 52 puntos y la posición número 8, fue el último club en clasificar a una copa internacional, mientras que, en la liga española, el Athletic Club de Bilbao, con 49 puntos y la posición 10, fue el último en clasificar a una competencia europea. Así, el parámetro para definir si un equipo es de mejor calidad en la temporada 2012-2013, es si en la temporada 2011-2012 quedo dentro de las primeras posiciones considerando hasta la última clasificada en una copa internacional europea. Entre los 20 clubes que contienen ambas ligas de primera división, en el caso de la Premier League, los 8 primeros clubes son los equipos de mejor calidad futbolística, y para LaLiga, los 10 primeros son los considerados buenos clubes.

  - Esta recodificación se puede ver a continuación, y se hizo siguiendo las tablas de posiciones o clasificaciones de la temporada pasada:

**Tabla de posiciones resultados temporada 2011-2012 Primera División Inglaterra.**
Fuente: *Premier League 2011-12*, 2023.

| Pos. | Equipo | Pts. | PJ | G | E | P | GF | GC | Dif. | Clasificación 2012-13 |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | **Manchester City (C)** | **89** | 38 | 28 | 5 | 5 | 93 | 29 | +64 | |
| 2 | Manchester United | **89** | 38 | 28 | 5 | 5 | 89 | 33 | +56 | Fase de grupos de la Liga de Campeones |
| 3 | Arsenal | **70** | 38 | 21 | 7 | 10 | 74 | 49 | +25 | |
| 4 | Tottenham Hotspur[a] | **69** | 38 | 20 | 9 | 9 | 66 | 41 | +25 | Fase de grupos de la Liga Europa |
| 5 | Newcastle United[a] | **65** | 38 | 19 | 8 | 11 | 56 | 51 | +5 | Play-offs de la Liga Europa |
| 6 | Chelsea[a] | **64** | 38 | 18 | 10 | 10 | 65 | 46 | +19 | Fase de grupos de la Liga de Campeones |
| 7 | Everton | **56** | 38 | 15 | 11 | 12 | 50 | 40 | +10 | |
| 8 | Liverpool[b] | **52** | 38 | 14 | 10 | 14 | 47 | 40 | +7 | Tercera ronda previa de la Liga Europa |
| 9 | Fulham | **52** | 38 | 14 | 10 | 14 | 48 | 51 | −3 | |
| 10 | West Bromwich Albion | **47** | 38 | 13 | 8 | 17 | 45 | 52 | −7 | |
| 11 | Swansea City | **47** | 38 | 12 | 11 | 15 | 44 | 51 | −7 | |
| 12 | Norwich City | **47** | 38 | 12 | 11 | 15 | 52 | 66 | −14 | |
| 13 | Sunderland | **45** | 38 | 11 | 12 | 15 | 45 | 46 | −1 | |
| 14 | Stoke City | **45** | 38 | 11 | 12 | 15 | 36 | 53 | −17 | |
| 15 | Wigan Athletic | **43** | 38 | 11 | 10 | 17 | 42 | 62 | −20 | |
| 16 | Aston Villa | **38** | 38 | 7 | 17 | 14 | 37 | 53 | −16 | |
| 17 | Queens Park Rangers | **37** | 38 | 10 | 7 | 21 | 43 | 66 | −23 | |
| 18 | Bolton Wanderers **(D)** | **36** | 38 | 10 | 6 | 22 | 46 | 77 | −31 | |
| 19 | Blackburn Rovers **(D)** | **31** | 38 | 8 | 7 | 23 | 48 | 78 | −30 | Descenso de categoría |
| 20 | Wolverhampton Wanderers **(D)** | **25** | 38 | 5 | 10 | 23 | 40 | 82 | −42 | |

**Tabla de posiciones resultados temporada 2011-2012 Primera División España.** Fuente: *Primera División de España 2011-12*, 2023.

| Pos. | Equipo | Pts. | PJ | G | E | P | GF | GC | Dif. | Clasificación |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | **Real Madrid (C)** | **100** | 38 | 32 | 4 | 2 | 121 | 32 | +89 | |
| 2 | Barcelona | **91** | 38 | 28 | 7 | 3 | 114 | 29 | +85 | CHAMPIONS LEAGUE |
| 3 | Valencia | **61** | 38 | 17 | 10 | 11 | 59 | 44 | +15 | |
| 4 | Málaga | **58** | 38 | 17 | 7 | 14 | 54 | 53 | +1 | CHAMPIONS LEAGUE |
| 5 | Atlético de Madrid[a] | **56** | 38 | 15 | 11 | 12 | 53 | 46 | +7 | EUROPA LEAGUE |
| 6 | Levante | **55** | 38 | 16 | 7 | 15 | 54 | 50 | +4 | EUROPA LEAGUE |
| 7 | Osasuna | **54** | 38 | 13 | 15 | 10 | 44 | 61 | −17 | |
| 8 | Mallorca | **52** | 38 | 14 | 10 | 14 | 42 | 46 | −4 | |
| 9 | Sevilla | **50** | 38 | 13 | 11 | 14 | 48 | 47 | +1 | |
| 10 | Athletic Club[b] | **49** | 38 | 12 | 13 | 13 | 49 | 52 | −3 | EUROPA LEAGUE |
| 11 | Getafe | **47** | 38 | 12 | 11 | 15 | 40 | 51 | −11 | |
| 12 | Real Sociedad | **47** | 38 | 12 | 11 | 15 | 46 | 52 | −6 | |
| 13 | Betis | **47** | 38 | 13 | 8 | 17 | 47 | 56 | −9 | |
| 14 | Espanyol | **46** | 38 | 12 | 10 | 16 | 46 | 56 | −10 | |
| 15 | Rayo Vallecano | **43** | 38 | 13 | 4 | 21 | 53 | 73 | −20 | |
| 16 | Real Zaragoza | **43** | 38 | 12 | 7 | 19 | 36 | 61 | −25 | |
| 17 | Granada | **42** | 38 | 12 | 6 | 20 | 35 | 56 | −21 | |
| 18 | Villarreal | **41** | 38 | 9 | 14 | 15 | 39 | 53 | −14 | |
| 19 | Sporting de Gijón | **37** | 38 | 10 | 7 | 21 | 42 | 69 | −27 | LIGA adelante |
| 20 | Racing de Santander | **27** | 38 | 4 | 15 | 19 | 28 | 63 | −35 | |

**Recodificación de la variable independiente de interés**:

```
clubes <- unique(base_final$club)
# print(clubes)

# Codificación de la variable independiente de calidad del club
base_final$buen_club <- rep(0,nrow(base_final))

# 8 Equipos de mejor calidad Inglaterra
base_final$buen_club[base_final$club=="Manchester United"] <- 1
base_final$buen_club[base_final$club=="Manchester City"] <- 1
base_final$buen_club[base_final$club=="Chelsea FC"] <- 1
base_final$buen_club[base_final$club=="Arsenal FC"] <- 1
base_final$buen_club[base_final$club=="Tottenham Hotspur"] <- 1
```

```r
base_final$buen_club[base_final$club=="Everton FC"] <- 1
base_final$buen_club[base_final$club=="Newcastle United"] <- 1
base_final$buen_club[base_final$club=="Liverpool FC"] <- 1

# 10 Equipos de mejor calidad España
base_final$buen_club[base_final$club=="Real Madrid"] <- 1
base_final$buen_club[base_final$club=="FC Barcelona"] <- 1
base_final$buen_club[base_final$club=="Valencia CF"] <- 1
base_final$buen_club[base_final$club=="Málaga CF"] <- 1
base_final$buen_club[base_final$club=="Atlético Madrid"] <- 1
base_final$buen_club[base_final$club=="Levante UD"] <- 1
base_final$buen_club[base_final$club=="CA Osasuna"] <- 1
base_final$buen_club[base_final$club=="RCD Mallorca"] <- 1
base_final$buen_club[base_final$club=="Sevilla FC"] <- 1
base_final$buen_club[base_final$club=="Athletic Bilbao"] <- 1

# Se confirma que la variable independiente quedó como dummy:
# print(base_final$buen_club)
table(base_final$buen_club) # No hay un desbalance notorio entre 0 y 1
```

```
  0   1
391 399
```

#### Justificación relación original

Para justificar la relación entre la cantidad de goles que mete un jugador y la calidad del club en el que juega, es decir, para justificar que **estar en un buen club es explicativo de los goles anotados a lo largo de la temporada**, se realiza un test estadístico. Se hace un **test de hipótesis** T de Welch (de medias) para dos muestras independientes (jugadores pertenecientes a un buen club y jugadores pertenecientes a un mal club).

- H0: La media de **`goles_totales`** es igual para ambos grupos de la variable **`buen_club`**.
- H1: La media de **`goles_totales`** es significativamente diferente entre ambos grupos de la variable **`buen_club`**, los jugadores de un buen equipo y los jugadores de un mal equipo.
- Usaremos el nivel de significancia común de 0.05 para rechazar H0, a un 95% de confianza.

```
Welch Two Sample t-test
```

```
data:  goles_totales by buen_club
t = -3.6972, df = 672.51, p-value = 0.0002357
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to
95 percent confidence interval:
 -18.823957  -5.765316
sample estimates:
mean in group 0 mean in group 1
       24.55499        36.84962
```

El resultado del test indica que la media de goles anotados es de 25 aproximadamente entre los jugadores de equipos malos, mientras que la media de goles entre jugadores de clubes buenos es de 37 goles aproximadamente. Estas medias son estadísticamente diferentes a un 95% de confianza, dado que se rechaza la hipótesis nula, considerando que el valor p del test es 0.000, lo que es menor al nivel de significancia de 0.05. Esto sugiere que estar en un buen o mal club, considerando la liga de primera división de la temporada previa, sí es predictivo de los goles anotados por los jugadores a lo largo de la temporada 2012-2013.

### Justificación variables de control

- Aparte, vamos a considerar ***variables de control***. Así, se va a controlar el efecto de jugar en un buen o mal club, por otras posibles covariables que podrían confundir la relación y estar aportando a la explicación de la variación en la variable dependiente. Si bien las variables seleccionadas no se relacionan de manera teórica muy directamente con la variable independiente de interés (`buen_club`), lo que limita llamarlas extrictamente "confounders", sí pueden relacionarse con la variable dependiente. A continuación se enlistan las variables de control consideradas en este trabajo, y luego se muestran las recodificaciones correspondientes que se debieron hacer.

  - **Edad** del jugador (`edad`): variable continua que da cuenta de la cantidad de años que tiene el jugador al inicio de la temporada 2012-2013 de la liga, específicamente, a la fecha 18 de agosto de 2012 que fue cuando comenzó. Se crea a partir de la variable `birthday` que había en la base de datos original. Se controla por esta variable por ser una variable física y sociodemográfica básica que puede afectar en el rendimiento del jugador, y a su vez eso lleva a que pueda meter más o menos goles. Se podría pensar que un jugador mas joven metería más goles que un jugador mayor, porque puede tener mejor estado físico, pero, al mismo, la edad puede dar cuenta de la trayectoria de experiencia jugando campeonatos, por lo que un jugador más joven es más inexperto que uno de mayor edad, y aquello podría explicar que meta menos goles, lo que es posible con los datos de esta base, considerando que el mínimo de edad en la muestra es 17 años.

- Peso del jugador (`weight`): variable continua que da cuenta de los kilogramos que pesa el jugador. Esta variable se incluye por ser indicadora de una característica física que puede ser importante y reflejar la capacidad de rendir físicamente del jugador.
- Altura del jugador (`height`): variable continua que da cuenta de los centímetros que mide el jugador. Al igual que el peso, esta variable da cuenta de una característica física que puede ser relevante. Se podría pensar que los jugadores más altos meten más goles, en base a que, de los cuatro jugadores que han metido más goles en el mundo (Ronaldo, Messi, Lewandowski, Suárez), tres miden más de 180 cm. Pero, en esta base de datos, Messi fue quien anotó más goles y es un jugador bastante bajo (169 cm) en comparación al promedio de 182 cm, por lo que vale la pena indagar en esta posible variable explicativa de los goles de un jugador.
- **Posición** del jugador (`posicion`): variable categórica nominal (4 categorías) que indica en qué posición de la cancha jugó el jugador de fútbol durante la temporada. Se crea a partir de la variable `position` en la base de datos original, recodificándola para disminuir la cantidad de categorías en posiciones más generales y familiares: defensa, medio campista, delantero, y portero. Esta variable es importante porque no es trivial a la hora de explicar los goles que mete un jugador. Un arquero tiene menos probabilidades de meter un gol que un delantero, por lo que es necesario capturar ese factor de variación en los modelos que se estimen.
- Partidos jugados por el jugador (`games_totales`): variable continua que indica el número de partidos en que participó el jugador durante la liga, creada a partir de una suma del valor de la variable `games`, en cada fila del jugador. Esta variable se usa para indicar la exposición a poder meter goles. Por lo tanto, será utilizada como "off-set" cuando se estimen modelos de regresión Poisson, como será explicado más adelante, para poder estimar las tasas de goles por partidos jugados. Cabe mencionar que en la realidad, cada equipo juega 38 partidos en total, 19 de ida y 19 de vuelta durante la liga, pero, sabemos que el recuento de partidos no se apega a la realidad por cómo está codificada la base de datos y que puede que haya más de un árbitro que contabilizó el mismo partido.

```r
# Recodificación de Edad
base_final$birthday <- as.Date(base_final$birthday, format = "%d.%m.%Y")
fecha_inicio_temporada <- as.Date("18.08.2012", format = "%d.%m.%Y")
base_final$edad <- as.numeric(difftime(fecha_inicio_temporada,
                                       base_final$birthday,
                                       units = "days") / 365.25)
base_final$edad <- round(base_final$edad, 1)
# print(base_final[, c("birthday", "edad")])
```

```r
# Recodificación de Posición: se reducen 12 categorías a 4 categorías
posiciones <- unique(base_final$position)
# print(posiciones)

base_final$posicion[base_final$position=="Center Back"] <- "Defensor"
base_final$posicion[base_final$position=="Left Fullback"] <- "Defensor"
base_final$posicion[base_final$position=="Right Fullback"] <- "Defensor"
base_final$posicion[base_final$position=="Defensive Midfielder"] <- "Centrocampista"
base_final$posicion[base_final$position=="Center Midfielder"] <- "Centrocampista"
base_final$posicion[base_final$position=="Attacking Midfielder"] <- "Centrocampista"
base_final$posicion[base_final$position=="Right Midfielder"] <- "Centrocampista"
base_final$posicion[base_final$position=="Left Midfielder"] <- "Centrocampista"
base_final$posicion[base_final$position=="Center Forward"] <- "Delantero"
base_final$posicion[base_final$position=="Right Winger"] <- "Delantero"
base_final$posicion[base_final$position=="Left Winger"] <- "Delantero"
base_final$posicion[base_final$position=="Goalkeeper"] <- "Portero"
table(base_final$posicion)
```

```
Centrocampista       Defensor      Delantero        Portero
           272            263            167             88
```

```r
# skimr::skim(base_final)
summary(base_final$edad) # el más joven tenía 17 y más viejo 41 años
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  17.10   23.60   26.60   26.83   30.00   41.30
```

```r
summary(base_final$weight)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  55.00   71.00   75.00   75.73   80.00   97.00
```

```r
summary(base_final$height)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  161.0   177.0   182.0   181.7   187.0   203.0
```

```r
summary(base_final$games_totales)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
    9.0   145.0   229.5   261.1   358.0   945.0 
```

| | skim_variable | n_missing | complete_rate | mean | sd | p0 | p25 | p50 | p75 | p100 | hist |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | <chr> | <int> | <dbl> | <dbl> | <dbl> | <dbl> | <dbl> | <dbl> | <dbl> | <dbl> | <chr> |
| 1 | height | 0 | 1 | 181.6708861 | 6.8797779 | 161.0 | 177.0 | 182.0 | 187 | 203.0 | |
| 2 | weight | 0 | 1 | 75.7303797 | 6.8410869 | 55.0 | 71.0 | 75.0 | 80 | 97.0 | |
| 3 | games | 0 | 1 | 2.8886076 | 3.4593781 | 1.0 | 1.0 | 1.0 | 3 | 30.0 | |
| 4 | goals | 0 | 1 | 0.2784810 | 0.7591722 | 0.0 | 0.0 | 0.0 | 0 | 10.0 | |
| 5 | goles_totales | 0 | 1 | 30.7645570 | 47.3076682 | 0.0 | 3.0 | 14.0 | 37 | 420.0 | |
| 6 | games_totales | 0 | 1 | 261.0506329 | 158.1714908 | 9.0 | 145.0 | 229.5 | 358 | 945.0 | |
| 7 | buen_club | 0 | 1 | 0.5050633 | 0.5002911 | 0.0 | 0.0 | 1.0 | 1 | 1.0 | |
| 8 | edad | 0 | 1 | 26.8293671 | 4.2941406 | 17.1 | 23.6 | 26.6 | 30 | 41.3 | |

8 rows

Por simplicidad, inicialmente **se seleccionan 2 controles** para incluir en el modelo de regresión: la **posición** del jugador y la **edad** del jugador; y *games* se usa como *off-set*. Pero, el resto de los controles mencionados se incluyen en la sección de Análisis Complementarios del informe. Aparte de las razones teóricas o sustantivas, para justificar la inclusión de las dos variables de control, se hacen un par de tests estadísticos.

Relación entre edad al inicio de la temporada y la cantidad de goles que hizo el jugador: Correlación de Pearson

- Hipótesis Nula H0: No hay correlación significativa entre **`goles_totales`** y **`edad`**.
- Hipótesis Alternativa H1: Existe una correlación significativa entre **`goles_totales`** y **`edad`**.
- Usaremos el nivel de significancia convencional de 0.05 para rechazar la H0, a un 95% de confianza.

```
	Pearson's product-moment correlation

data:  base_final$goles_totales and base_final$edad
t = 4.6924, df = 788, p-value = 0.000003183
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.09622719 0.23195647
sample estimates:
      cor 
0.1648723 
```

Se rechaza la hipótesis nula, ya que el valor p es aproximadamente 0.000, siendo menor al nivel de significancia 0.05. Por lo tanto, si bien el coeficiente de correlación es relativamente bajo

(0.165), esa correlación sí parece ser significativa, y por ende hay una relación entre la edad del jugador y los goles que anota a lo largo de la temporada de la liga.

Relación entre edad al inicio de la temporada y la posición del jugador: Análisis de Varianza (ANOVA)

- Hipótesis Nula H0: No hay relación significativa entre **`goles_totales`** y **`posición`**.
- Hipótesis Alternativa H1: Existe una relación significativa entre **`goles_totales`** y **`posición`**.
- Usaremos el nivel de significancia convencional de 0.05 para rechazar la H0, a un 95% de confianza.

```
            Df  Sum Sq Mean Sq F value              Pr(>F)
posicion     3  615107  205036   140.1 <0.0000000000000002 ***
Residuals  786 1150687    1464
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El resultado indica que se rechaza la hipótesis nula a 95% de significancia, pues el valor p es prácticamente 0, menor que el nivel de significancia de 0.05. Por lo tanto, la variable de la posición del jugador sí explica significativamente la variabilidad observada en la variable de cantidad de goles que hace el jugador.

### Volviendo a la pregunta de investigación…

Auspurg y Brüderl (2021), en el artículo "Has the Credibility of the Social Sciences Been Credibly Destroyed? Reanalyzing the"Many Analysts, One Data Set" Project", señalan que, a pesar de haber sido instruidos con la misma pregunta de investigación, diferentes equipos de investigación pueden interpretar una misma pregunta de formas distintas.

Para este trabajo se elige una **interpretación del tipo 2 –estudiar el efecto de la variable independiente sobre la variable dependiente neto de posibles 'confounders'-**.

Finalmente, la pregunta empírica claramente definida es: *¿tiene un efecto estar en un buen o mal club, según el rendimiento en la temporada 2011-2012, sobre la cantidad de goles que marca un jugador de la liga de primera división, en Inglaterra y en España durante la temporada 2012-2013, controlando por la edad y la posición del jugador?*

Estar en un buen o mal club no tendría por qué relacionarse con la posición del jugador, pero, la posición del jugador evidentemente afecta a la cantidad de goles que este puede hacer, por lo que vale la pena controlar por esta variable para estudiar el efecto de la calidad del club entre jugadores de la misma posición. Al mismo tiempo, la edad del jugador tampoco tendría una razón teórica para relacionarse con estar en un buen o mal club, pero como se muestra

anteriormente, sí se relaciona con los goles anotados por un jugador, y controlar por esta variable implicaría estudiar el efecto de la calidad del club manteniendo constante la edad de los jugadores. Y, se esperaría que el efecto de la calidad del club sobre los goles del jugador sea mayor que la asociación bivariada entre la posición y los goles, y entre la edad y los goles.

Si la interpretación fuera del tipo 3 –desarrollar un modelo predictivo para la variable dependiente de interés-, nuestra pregunta sería "¿qué factores predicen la cantidad goles marcados por un jugador?". Se modelaría la cantidad de goles marcados en toda la temporada, como función de todos los factores observados que podrían tener un efecto: buen club, posición, edad, altura, peso; bajo el razonamiento de que los goles dependerían de todas esas variables. Si bien en nuestro caso sí hay una intuición de que los goles dependen de las variables seleccionadas, hay un interés primordial, y una relación original que se busca evaluar: el efecto de estar en un buen club sobre los goles totales anotados.

## Modelo de regresión Poisson

Ahora se muestran la decisión sobre la **forma funcional** de nuestros modelos de regresión. Es decir, la relación algebráica entre variables dependiente e independientes. Se expresa a continuación formalmente la ecuación correspondiente:

$f(golestotales_i) = \beta_0 + \beta_1 * buenclub_i + \beta_2 * posicion_i + \beta_3 * edad_i$

Siguiente, se justifica la utilización del **tipo de modelo**. El tipo de modelo de regresión que mejor se ajusta al tipo de datos, para responder a la pregunta empírica, es uno **Poisson,** debido a que esta es la herramienta estandar para modelar variables de conteo como es el caso de la cantidad de goles totales por jugador, que es la variable que buscamos explicar, para estimar conteos de goles. Sumado a esto, la regresión Poisson aparece como relevante cuando el fenómeno de interés son tasas, y esto es importante para el presente informe debido al interés de conocer la tasa de goles por jugador por partido, para evitar estar sesgados. Además, la regresión Poisson por definición utiliza función de enlace log. Se seleccionó este modelo dado que permitirá modelar la cantidad esperada (recuento, cantidad de goles) de goles por jugador dadas la variable independiente y las dos variables de control, teniendo como offset la cantidad de partidos en el caso de los modelos de tasas.

Luego de limpiar la base de datos y recodificar los valores necesarios, podemos estimar los modelos. Los modelos de tasas se hacen con la cantidad de partidos (`games_totales`) como la exposición u "off-set". Todos los modelos se estiman con un **N=790 jugadores**, esas son las observaciones independientes $i$ que tenemos. Para cada observación $i$ observamos datos $y_i$ que actúan como variable dependiente, y son un número entero no negativo.

$Y \sim Poisson(\mu_i)$ donde $Y$ es la variable aleatoria "goles totales" que puede ser descrita con una distribución Poisson, y $\mu$ corresponde al valor esperado de la variable: el número de goles totales promedio. Este parámetro puede variar entre observaciones, y se describe en función

de las covariables seleccionadas, que se van agregando paulatinamente a la especificación del modelo.

**Modelo 1:**

El primer modelo de regresión Poisson es el más simple del informe, que servirá como primer acercamiento a la respuesta de la pregunta. Este busca evaluar cómo afecta la calidad del club en la cantidad de goles esperada por jugador, sin incluir ninguna variable de control.

$ln(goles_i) = \beta_0 + \beta_1 *_{buenclub}$

$E(y_{goles}|x_{buenclub}) = \mu_i = e^{\beta_0 + \beta_1 *_{buenclub}}$

```
poisson_m1 <- glm(goles_totales ~ factor(buen_club),
                  family=poisson(link="log"), data=base_final)
```

**Modelo 2:**

El segundo modelo sigue la línea de lo anterior, pero será un modelo de tasas en vez de uno de recuento. Este busca observar cómo afecta la calidad del club en la cantidad de goles (como tasa, teniendo `games_totales` como *offset*) sin ninguna variable de control. Presentar el modelo también en forma de tasas permite hacerse cargo de las diferencias que puede ejercer

el nivel de exposición a la posibilidad de meter goles, es decir la cantidad de partidos jugados. Aquello, debido a que un jugador puede meter menos goles no por ser un peor jugador, sino por haber jugado menos partidos. De esta forma, este modelo permitirá conocer la tasa de goles por jugador por partido dada la calidad del club.

$ln(goles_i) = \beta_0 + \beta_1 * buenclub + ln(games_i)$

$E(y_{goles}|x_{buenclub}) = \mu_i = games_i * e^{\beta_0 + \beta_1 * buenclub}$

```
poisson_m2 <- glm(goles_totales ~ factor(buen_club),
                  family=poisson(link="log"),
                  offset=log(games_totales), data=base_final)
```

**Modelo 3:**

El tercer modelo será nuevamente una regresión poisson de recuento, pero esta vez buscará estimar cómo afecta la calidad del club en la cantidad de goles (recuento) controlando por la posición del jugador.

$ln(goles_i) = \beta_0 + \beta_1 *_{buenclub} + \beta_2 *_{posicion}$

$E(y_{goles}|x_{buenclub}, x_{posicion}) = \mu_i = e^{\beta_0 + \beta_1 * buenclub + \beta_2 * posicion}$

```
poisson_m3 <- glm(goles_totales ~ factor(buen_club) + factor(posicion),
                  family=poisson(link="log"), data=base_final)
```

**Modelo 4:**

En línea con el modelo anterior, el modelo 4 permite observar cómo afecta la calidad del club en la cantidad de goles (tasa, con offset games), controlando por posición.

$ln(goles_i) = \beta_0 + \beta_1 * buenclub + \beta_2 * posicion + ln(games_i)$

$E(y_{goles}|x_{buenclub}) = \mu_i = games_i * e^{\beta_0 + \beta_1 * buenclub + \beta_2 * posicin}$

```
poisson_m4 <- glm(goles_totales ~ factor(buen_club) + factor(posicion),
                  family=poisson(link="log"), offset=log(games_totales),
                  data=base_final)
```

**Modelo 5:**

El modelo 5 vuelve a aumentar la complejidad en términos de controles. Este busca observar cómo afecta la calidad del club en la cantidad de goles esperada (recuento), controlando por la posición y también se agrega la variable de la edad del jugador.

$ln(goles_i) = \beta_0 + \beta_1 *_{buenclub} + \beta_2 *_{posicion} + \beta_3 *_{edad}$

$E(y_{goles}|x_{buenclub}) = \mu_i = e^{\beta_0 + \beta_1 * buenclub + \beta_2 * posicion + \beta_3 * edad}$

```r
poisson_m5 <- glm(goles_totales ~ factor(buen_club) + factor(posicion) +
                    edad, family=poisson(link="log"), data=base_final)
```

**Modelo 6:**

Por último, el modelo 6 sigue la lógica de controles del modelo 5, pero es un modelo de tasas. De esta forma, busca ver cómo afceta la calidad del club en la cantidad de goles (tasa, offset games), controlando por posición y edad.

$ln(goles_i) = \beta_0 + \beta_1 * buenclub + \beta_2 * posicion + \beta_3 * edad + ln(games_i)$

$E(y_{goles}|x_{buenclub}) = \mu i = games_i * e^{\beta_0 + \beta_1 * buenclub + \beta_2 * posicin + \beta_3 * edad}$

```r
poisson_m6 <- glm(goles_totales ~ factor(buen_club) + factor(posicion) +
                    edad , family=poisson(link="log"),
                  offset=log(games_totales), data=base_final)
```

A continuación, se resumen todos los modelos estimados, partiendo por los tres modelos de recuento y siguiendo por los tres modelos de tasas.

1. Modelos de recuento

```
=========================================================================
                            1                3                5
-------------------------------------------------------------------------
(Intercept)                   3.201 ***        3.162 ***        0.062
                             (0.010)          (0.014)          (0.050)
factor(buen_club)1            0.406 ***        0.358 ***        0.533 ***
                             (0.013)          (0.013)          (0.013)
factor(posicion)Defensor                      -0.962 ***       -1.033 ***
                                              (0.022)          (0.022)
factor(posicion)Delantero                      1.031 ***        1.079 ***
                                              (0.014)          (0.014)
factor(posicion)Portero                       -4.993 ***       -5.334 ***
                                              (0.243)          (0.243)
edad                                                            0.110 ***
                                                               (0.002)
-------------------------------------------------------------------------
AIC                        40206.736        21187.077        16667.683
BIC                        40216.080        21210.437        16695.716
Log Likelihood            -20101.368       -10588.539        -8327.842
Deviance                   37002.636        17976.977        13455.584
Num. obs.                    790              790              790
```

```
=========================================================================
*** p < 0.001; ** p < 0.01; * p < 0.05
```

Para comenzar, en el modelo 1 (que no agrega controles) la cantidad de goles esperados para jugadores de un mal club (intercepto) es de $e^{3.201} = 24.5$ y se observa que el valor es significativo al 99.9% de confianza. Sumado a esto, se observa que la calidad del equipo tiene un efecto positivo significativo a un 99.9% de confianza en la cantidad de goles esperados por jugador. Es decir, jugar en un equipo bueno, en comparación a un equipo malo, tiene un efecto en hacer más goles, y este efecto es de aumentar en 0.406 el logaritmo natural del recuento de goles. Jugar en un equipo bueno, en vez de en uno malo, multiplica en $e^{0.406} \approx 1.5$ el recuento de los goles. Esto lleva a responder que sí hay un efecto positivo, según nuestra pregunta.

Además, se observa que si se suman los controles de posición y edad, la diferencia sigue siendo significativamente positiva entre jugar en un equipo bueno y uno malo. Es decir, incluso controlando por posición y por edad, pertener a un equipo bueno en comparación a uno malo tiene un impacto positivo en la cantidad de goles por jugador, pues aumenta en 0.533 el logaritmo natural del recuento de goles, ceteris paribus, a un 99.9% de confianza (modelo 5). En el modelo 3, el efecto de estar en un buen club en comparación a uno malo multiplica el recuento de goles por $e^{0.358} \approx 1.4$, con la misma significancia estadística. Mientras que, en el modelo 5, que agrega el control por edad, aparte de la posición, el efecto multiplicativo es $e^{0.533} \approx 1.7$ sobre el recuento para un jugador que está en un equipo bueno en comporación a uno de un equipo malo.

En base a estos modelos, también se puede afirmar que la posición del jugador tiene un efecto significativo sobre el logaritmo natural del recuento de goles. Tanto un portero como un defensor tienen menores cantidades de goles esparados que un mediocampista de un buen equipo, lo que es significativo en el modelo 3 y 5. Por el contrario, un jugador delantero tiene mayores goles esperados que un medio campista, según ambos modelos 3 y 5. Por último en relación con la edad, se observa que esta igualmente tiene un efecto significativo en el modelo 5: un cambio en un año adicional de edad, supone un aumento en 0.110 del logaritmo natural del recuento de goles del jugador, ceteris paribus, a un 99.9% de confianza.

Por último, analizando los ajustes de cada modelo, observando AIC, BIC y log likelihood, se puede determinar que el modelo 5 es el que tiene la mayor capacidad de explicar la variación de los datos en la variable dependiente de recuento de goles.

2. Modelos de tasas

```
=========================================================================
                           2               4               6
-------------------------------------------------------------------------
(Intercept)                    -2.255 ***      -2.325 ***      -2.702 ***
                               (0.010)         (0.014)         (0.053)
```

```
factor(buen_club)1              0.202 ***      0.175 ***      0.194 ***
                               (0.013)        (0.013)        (0.013)
factor(posicion)Defensor                      -0.928 ***     -0.940 ***
                                              (0.022)        (0.022)
factor(posicion)Delantero                      0.997 ***      1.005 ***
                                              (0.014)        (0.014)
factor(posicion)Portero                       -4.850 ***     -4.891 ***
                                              (0.243)        (0.243)
edad                                                          0.013 ***
                                                             (0.002)
---------------------------------------------------------------------
AIC                          27631.874      10226.783      10174.519
BIC                          27641.218      10250.143      10202.551
Log Likelihood              -13813.937      -5108.391      -5081.260
Deviance                     24427.774       7016.683       6962.419
Num. obs.                      790            790            790
=====================================================================
*** p < 0.001; ** p < 0.01; * p < 0.05
```

Para el objetivo de este informe, son de mayor utilidad los modelos de tasas, debido a que estos incorporan como offset la cantidasd de partidos jugados, lo que permite que no se penalice en términos de esperanza de goles a jugadores que jugaron una menor cantidad de partidos.

En primer lugar, analizando los tres modelos, se puede observar que jugar en un buen club tiene un efecto positivo en el logaritmo natural de la tasa de goles por partido.

En el modelo 4, primero, el efecto de estar en un buen club sobre el logaritmo natural de la tasa de goles por partido es positivo, aumentando la tasa en 0.175, y es además estadísticamente significativo a un 99.9% de confianza. En segundo lugar, el efecto de ser defensa en comparación a ser mediocampista sobre el logaritmo natural de la tasa de goles es de -0.928, y es estadísticamente significativo a un 99.9% de confianza. Se observa además que, para el caso de los delanteros, el logaritmo natural de su tasa de goles es 1.014 mayor que los mediocampistas, y ser portero disminuye el logaritmo natural de la tasa de goles en -4.850 (ambos valores son también significativos a un 99.9% de confianza). Esto quiere decir que la posición del jugador tiene un efecto multiplicativo -postivo para el caso de los delanteros y negativo para el caso de defensas y porteros, en contraste con los mediocampo- en la tasa de goles esperados por partido. Por ende, fue acertado incorporar esta variable de control.

Pasando al modelo 6, se observa que las direcciones y significancias de los efectos de estar en un buen club y de las posiones se mantienen. Es relevante notar que el efecto de estar en un buen club aumenta al pasar al modelo 6, con respecto a los anteriores, por lo que al controlar por edad y posición, es mayor el efecto sobre el logaritmo natural de la tasa de goles (0.194) a un 99.9% de confianza. En particular, para los jugadores ingleses y españoles, estar en un buen club (`buen_club`=1) en vez de en un mal club (`buen_club`=0), multiplica la tasa de ocurrencia

de meter goles en los partidos de la temporada 2012-2013 por 1.214 aproximadamente; ese es el efecto multiplicativo. Aparte, se observa que la edad tiene un efecto de 0.013 sobre el logaritmo natural de la tasa de goles por partido, y, a pesar de ser un coeficiente relativamente pequeño, se observa que el efecto es significativo a un 99.9% de confianza. Nuevamente, sí valía la pena incorporar el control de edad, pues permitió capturar un efecto más acertado de pertenecer a un buen club, notando que es más fuerte de lo que se sabría si no se hubiera incorporado el control.

Por último, comparando los ajustes de los seis modelos, es evidente que el mejor modelo es el Nº6 (BIC 10202.551).

Finalmente, se hace una tabla con los seis modelos estimados.

Como patrón general, se aprecia que a medida que se van agregando los controles de posición y edad, las medidas de bondad del ajuste van mejorando. Tanto el AIC como el BIC son menores en los modelos que incluyen a las dos variables de control. La diferencia entre los BIC es lo suficientemente grande como para afirmar que hay evidencia muy fuerte a favor de que los modelos con más controles mejoran el ajuste del modelo a los datos. Aquello es especialmente interesante, considerando que el BIC es la medida de ajuste más exigente, porque penaliza por la cantidad de parámetros. Además, es relevante para la pregunta de investigación, notar que el efecto de estar en un equipo de mejor calidad, es decir, la pertenencia a un buen club, es robusto, porque se sostiene al agregar los controles y no pierde significancia. Comparando los primeros modelos, simples, sin controles, con los últimos modelos, que incluyen posición y edad del jugador, el efecto no solo mantiene su significancia y dirección positiva, sino que también aumenta su magnitud. Es decir, al dar cuenta del efecto de la posición y la edad sobre la cantidad de goles, por estar controlando por esas variables en el modelo, se aprecia que el efecto de estar en un buen club es positivo y bastante grande a un 99.9% de confianza estadística.

En conclusión, se aprecia que efectivamente estar en un equipo de mejor calidad, es decir, estar entre los mejores equipos de la primera división, en contraste con estar entre los peores equipos de la primera división según la temporada anterior (2011-2012), tiene un efecto positivo sobre el recuento y la tasa de los goles que hacen los jugadores de Inglaterra y España a lo largo de toda la temporada de primera división 2012-2013.

```
texreg(l=list(poisson_m1, poisson_m2, poisson_m3, poisson_m4,
              poisson_m5, poisson_m6), single.row=FALSE, digits=3,
       caption="Modelos de regresión Poisson para goles totales",
          custom.model.names = c("1", "2", "3", "4", "5", "6"),
       caption.above = T)
```

Table 1: Modelos de regresión Poisson para goles totales

| | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| (Intercept) | $3.201^{***}$ | $-2.255^{***}$ | $3.162^{***}$ | $-2.325^{***}$ | 0.062 | $-2.702^{***}$ |
| | (0.010) | (0.010) | (0.014) | (0.014) | (0.050) | (0.053) |
| factor(buen_club)1 | $0.406^{***}$ | $0.202^{***}$ | $0.358^{***}$ | $0.175^{***}$ | $0.533^{***}$ | $0.194^{***}$ |
| | (0.013) | (0.013) | (0.013) | (0.013) | (0.013) | (0.013) |
| factor(posicion)Defensor | | | $-0.962^{***}$ | $-0.928^{***}$ | $-1.033^{***}$ | $-0.940^{***}$ |
| | | | (0.022) | (0.022) | (0.022) | (0.022) |
| factor(posicion)Delantero | | | $1.031^{***}$ | $0.997^{***}$ | $1.079^{***}$ | $1.005^{***}$ |
| | | | (0.014) | (0.014) | (0.014) | (0.014) |
| factor(posicion)Portero | | | $-4.993^{***}$ | $-4.850^{***}$ | $-5.334^{***}$ | $-4.891^{***}$ |
| | | | (0.243) | (0.243) | (0.243) | (0.243) |
| edad | | | | | $0.110^{***}$ | $0.013^{***}$ |
| | | | | | (0.002) | (0.002) |
| AIC | 40206.736 | 27631.874 | 21187.077 | 10226.783 | 16667.683 | 10174.519 |
| BIC | 40216.080 | 27641.218 | 21210.437 | 10250.143 | 16695.716 | 10202.551 |
| Log Likelihood | −20101.368 | −13813.937 | −10588.539 | −5108.391 | −8327.842 | −5081.260 |
| Deviance | 37002.636 | 24427.774 | 17976.977 | 7016.683 | 13455.584 | 6962.419 |
| Num. obs. | 790 | 790 | 790 | 790 | 790 | 790 |

$^{***}p < 0.001$; $^{**}p < 0.01$; $^{*}p < 0.05$

## Análisis Complementarios (BONUS)

### Modelos con variables de control adicionales

A continuación, se estiman los modelos de regresión Poisson agregando las variables de control de peso y altura del jugador.

Modelo 7: ver cómo afecta el club en la cantidad de goles (**recuento**), controlando por posición, edad, peso, altura.

$ln(goles_i) = \beta_0 + \beta_1 * buenclub + \beta_2 * posicion + \beta_3 * edad + \beta_4 * peso + \beta_5 * altura$

```
poisson_m7 <- glm(goles_totales ~ factor(buen_club) + factor(posicion) +
                    edad + weight + height, family=poisson(link="log"),
                  data=base_final)
```

Modelo 8: ver cómo afecta el club en la cantidad de goles (**tasa**, con offset games), controlando por posición, edad, peso, altura.

$ln(goles_i) = \beta_0 + \beta_1 * buenclub + \beta_2 * posicion + \beta_3 * edad + \beta_4 * peso + \beta_5 * altura + ln(games_i)$

```
poisson_m8 <- glm(goles_totales ~ factor(buen_club) + factor(posicion) +
                    edad + weight + height, family=poisson(link="log"),
                  offset=log(games_totales), data=base_final)
```

Visualizar los nuevos modelos:

```
=========================================================
                           Modelo Recuento  Modelo Tasa
---------------------------------------------------------
(Intercept)                   -1.161 ***       -3.529 ***
                              (0.208)          (0.201)
factor(buen_club)1             0.543 ***        0.203 ***
                              (0.013)          (0.013)
factor(posicion)Defensor      -1.078 ***       -0.984 ***
                              (0.022)          (0.022)
factor(posicion)Delantero      1.062 ***        0.988 ***
                              (0.014)          (0.014)
factor(posicion)Portero       -5.440 ***       -4.996 ***
                              (0.243)          (0.243)
edad                           0.109 ***        0.012 ***
                              (0.002)          (0.002)
weight                         0.004 **         0.008 ***
```

```
                              (0.002)          (0.002)
height                         0.005 ***        0.001
                              (0.001)          (0.001)
-------------------------------------------------------
AIC                        16597.799        10094.096
BIC                        16635.175        10131.473
Log Likelihood             -8290.899        -5039.048
Deviance                   13381.699         6877.997
Num. obs.                    790              790
=======================================================
*** p < 0.001; ** p < 0.01; * p < 0.05
```

Se va a interpretar el resultado de agregar los controles de peso y altura a partir del output del Modelo Nº8, para tasas: El efecto del peso sobre el logaritmo natural de la tasa de goles totales es de 0.008, estadísticamente significativo a un 95% de confianza, ceteris paribus. A la vez, el efecto de la altura sobre el logaritmo natural de la tasa de goles totales es de 0.001, pero no es estadísticamente significativo a niveles convencionales de confianza, ceteris paribus. Cabe mencionar, que llama la atención que en el modelo de recuento (Nº7) el coeficiente de la altura sí teine significancia estadística, y el coeficiente del peso tiene menor significancia. El efecto de mayor interés en realidad corresponde al de "`buen_club`": el efecto de estar en un buen club en contraste con estar en un mal club de la primera división, sobre el logaritmo natural de la tasa de goles totales, es de 0.203, estadísticamente significativo a un 99.9% de confianza, ceteris paribus. Al comparar dicho efecto con el modelo anterior de tasa, el modelo número 6, se nota que el efecto mantiene su significancia estadística y dirección, y aumenta la magnitud, puesto que el coeficiente de `buen_club` en el modelo Nº6 era de 0.194, lo que sugiere que, **incluso al agregar más variables de control que se asocian con la cantidad de goles que un jugador puede hacer en total, el efecto de estar en un buen club aumenta, manteniéndose robusto, positivo y significativo**.

### Comparar medida de bondad del ajuste: BIC (N=790)

Se decide comparar los BIC de los modelos, el Bayesian Information Criterion, porque es la medida de ajuste más exigente, ya que penaliza por cantidad de parámetros, por lo que tiene preferencia por modelos con menos variables. Entonces, si el BIC mejora sustantivamente, a pesar de que penaliza, se puede pensar que realmente la mejora en ajuste (BIC más bajo) es importante.

Table 2: Indicador de ajuste de los modelos

| Modelos | BIC |
|---|---:|
| Recuento solo con posición | 21210.44 |
| Tasa solo con posición | 10250.14 |

| Modelos | BIC |
|---|---|
| Recuento agregando edad | 16695.72 |
| Tasa agregando edad | 10202.55 |
| Recuento agregando peso y altura | 16635.18 |
| Tasa agregando peso y altura | 10131.47 |

- Siguiendo las Reglas de Raftery, sí hay suficiente evidencia para afirmar que los BIC de los modelos en que se agregan las variables de peso y altura son menores que los BIC en que solo están los controles por posición y edad, puesto que las diferencias son de más de 10 puntos.
  - En el caso de los modelos de recuento, la diferencia entre el modelo que incluye posición y edad, con el BIC del modelo que agrega peso y altura también, es de 60.54 puntos. Por lo tanto, la evidencia es fuerte para decir que el último modelo es más explicativo de la variación en la variable dependiente, y permitiría capturar un efecto más robusto y realista de estar en un buen o mal club.
  - Por el lado de los modelos de tasas, la diferencia entre el modelo que incluye posición y edad, con el BIC del modelo que agrega peso y altura también, es de 71.08 puntos que decrece el BIC al agregar las últimas dos variables, y siempre considerando la exposición a los partidos jugados. Por lo tanto, la evidencia es fuerte para decir que el último modelo es, considerando todos los modelos de tasas, el más explicativo de la variación en la variable dependiente, y permitiría capturar un efecto más robusto y realista de estar en un buen o mal club.

### Cantidades de interés

1. Estimación del efecto multiplicativo de buen club sobre goles, para el modelo de tasas con mejor ajuste en términos de BIC, que es el Nº6.

Para los jugadores ingleses y españoles, estar en un buen club (`buen_club`=1) en vez de en un mal club (`buen_club`=0), multiplica la tasa de ocurrencia de meter goles en los partidos de la temporada 2012-2013 por 1.214 aproximadamente, a un 99.9% de confianza, ceteris paribus (controlando por posición y edad del jugador).

```r
exp(0.194) # 1.214096
```

```
[1] 1.214096
```

2. Estimación de la cantidad esperada de goles anotados para un jugador en una posición de delantero (`posicion`=delantero), en la mediana de edad (26.6 años), que jugó 230 partidos de la liga de primera división (o sea, aprox la mediana de `games_totales`, aunque no sea realista). En base al modelo Nº6, de tasas.

Sabemos que… $e^{\beta_0} \cdot n_i$ es el recuento esperado cuando $x_1 = \cdots = x_k = 0$. $n_i$ en este caso corresponde a los partidos de la temporada en los que participó el jugador de primera división (`games_totales`). Al multiplicar la tasa de ocurrencia del evento (goles) por la exposición (partidos), se tienen los recuentos de goles totales. Se hace el cálculo en base a la siguiente ecuación, reemplazando por los valores de las variables en que se decide fijar:

$goles_i = e^{\beta_0} \cdot e^{\beta_1 buenclub_i} \cdot e^{\beta_2 posicion_i} \cdot e^{\beta_3 edad_i} \cdot games_i$

```
# Cálculo de la cantidad esperada:
recuento_esperado <- exp(-2.702) * exp(0.194*1) * exp(-0.940*0) *
  exp(1.005*1) * exp(-4.891*0) * exp(0.013*26.6) *230
recuento_esperado # 72.30399 goles
```

```
[1] 72.30399
```

El resultado del cálculo del recuento de goles, a partir del modelo Poisson con offset, fue de 72.3 goles aproximadamente, fijando ciertas características de los jugadores (posición y edad) y los 230 partidos jugados en la temporada (exposición). La cantidad esperada de goles para un jugador delantero con 26.6 años y que jugó 230 partidos (hipotéticamente) es de 72 aproximadamente.

3. Fijar las mismas características: buscar dos jugadores que tengan una posición, edad, peso y altura similar, y modelar la cantidad de goles, pero que uno juegue en un equipo "no bueno" y el otro en un equipo "bueno". Además, que hayan estado expuestos a la misma cantidad de partidos. En base al modelo Nº8, de tasas.

Al hacer predicciones, hay que fijar la exposición "games" porque de eso depende la tasa esperada. Al multiplicar la tasa de ocurrencia del evento por la exposición, se tienen los recuentos, en este caso, en base al modelo 8.

$\mu_i$ corresponde al valor esperado de la variable aleatoria `goles_totales`. Hay que seguir la siguiente lógica para calcular los valores predichos de recuentos, especificando los valores de las variables independinetes en que se decide fijar, y obteniendo los coeficientes del modelo de regresión poisson Nº8.

$\mu_i = e^{\beta_0} \cdot e^{\beta_1 buenclub_i} \cdot e^{\beta_2 posicion_i} \cdot e^{\beta_3 edad_i} \cdot e^{\beta_4 peso_i} \cdot e^{\beta_5 altura_i} \cdot games_i$

- Jugador 1: Delantero de 30 años, mide 182 cm y pesa 78 kg. Juega en un equipo "no bueno". 145 partidos.

```
# Calculo de la cantidad esperada:
cant_jug1 = exp(-3.529) * exp(0.203*0) * exp(-0.984*0) *
  exp(0.988*1) * exp(-4.996*0) * exp(0.012*30) *
  exp(0.008*78) * exp(0.001*182) *145
```

```r
cant_jug1 # 36.66174 goles
```

```
[1] 36.66174
```

- Jugador 2: Delantero de 30 años, mide 182 cm y pesa 78 kg. Juega en un equipo "bueno". 145 partidos.

```r
cant_jug2 = exp(-3.529) * exp(0.203*1) * exp(-0.984*0) *
  exp(0.988*1) * exp(-4.996*0) * exp(0.012*30) *
  exp(0.008*78) * exp(0.001*182) *145
cant_jug2 # 44.91329 goles
```

```
[1] 44.91329
```

Ante las mismas características, de posición, edad, altura y peso, y habiéndose expuesto a la misma cantidad de partidos a lo largo de la liga (el valor que marca el primer cuartil o la posición del 25% en la muestra: 145 partidos), un jugador que pertenece a un buen club mete más goles que un jugador de un mal club. El recuento esperado para el jugador de un buen equipo es de 44 goles, mientras que el recuento esperado para el jugador de un club de peor calidad es de 36 goles. Esta diferencia en goles predichos es grande, lo que reafirma nuestras intuiciones de la relación original. Además, se aprecia la relevancia de controlar por variables que sí afectan en los goles de un jugador, porque permite hacer comparables en todo sentido a dos jugadores, excepto por estar en un equipo de peor o mejor calidad. Por ende, la oportunidad de goles que puede hacer un jugador de España o Inglaterra en la temporada presente es mucho mayor estando con un equipo de alta calidad, de los primeros posicionados en la liga de primera división de la temporada anterior.

4. Efectos marginales sobre mu, recuentos.

Se analizan las variables de control, porque tanto la posición del jugador como la edad del jugador afectaban en la cantidad de goles. Aunque no fuera el foco del trabajo esas relaciones, se hace interesante observar el efecto marginal de la edad del jugador sobre el recuento de goles, considerando las distintas posiciones que tienen. El efecto marginal de la edad crece a medida que los jugadores tienen más expriencia, es decir, que son más grandes en edad, y este patrón del efecto se da en mayor medida en los delanteros, como es de esperarse, seguido de los que juegan medio-campo, a defensa, y manteniéndose en cero el efecto marginal para los arqueros.

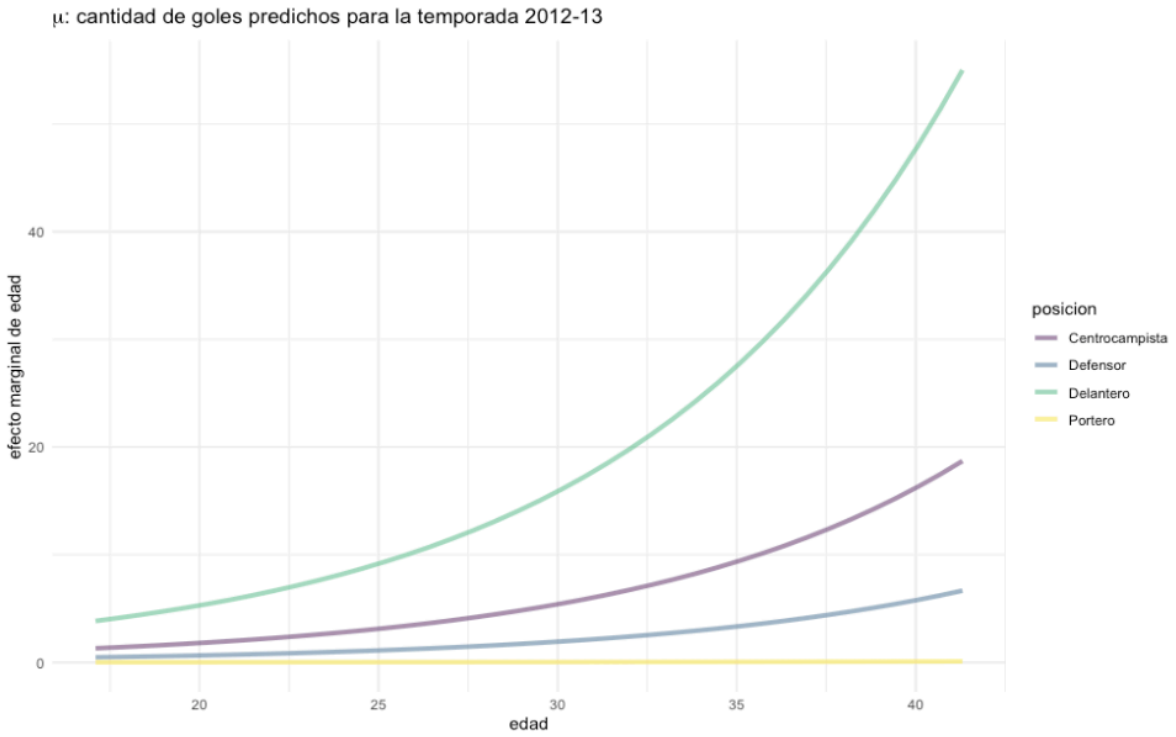


**Boxplot: goles totales por calidad del equipo**

Se realiza un gráfico de caja para visualizar la distribución de la cantidad de goles en cada categoría de la variable independiente binaria. Esto permite entender que la cantidad de goles totales que hace un jugador de Inglaterra o España a lo largo de la temporada 2012-2013 es función de si su equipo es un buen o mal club, según su rendimiento y por ende posición durante la temporada 2011-2012 de la liga de primera división de su país.

Se puede notar que el mínimo de goles para ambos tipos de equipos es el mismo: 0 goles. El punto que marca el primer cuartil (25%) es más alto para los jugadores de un buen club que para los jugadores de un mal club. Asimismo, la mediana es mayor en quienes pertenecen a un equipo de mejor calidad. Luego, el tercer cuartil es bastante mayor para los jugadores de un buen club, estando el percentil 75 cercano a los 50 goles totales a lo largo de la temporada, en contraste con los jugadores de un peor club de la primera división. El último 25% se extiende entre valores mucho más altos para los jugadores de un buen club que de un mal club, llegando el valor máximo a los 100 y 75 goles aproximadamente, respectivamente. Por último, ambos grupos presentan outliers. En el grupo de los malos clubes, hay 2 jugadores que ubicados cerca de los 250 goles, siendo estos los valores más extremos. Pero, en el caso de los buenos clubes, hay bastante más jugadores cercanos a los 250 goles, y además tienen valores aún más extremos, con algunos jugadores cercanos a haber logrado 300 goles, y otro que incluso supera los 400 goles, que sabemos que es Lionel Messi, quien jugaba en el FC Barcelona. En

conclusión, en general, los jugadores de buenos clubes tienen un mayor recuento de goles a lo largo de la temporada que sus pares de malos clubes de la primera división.

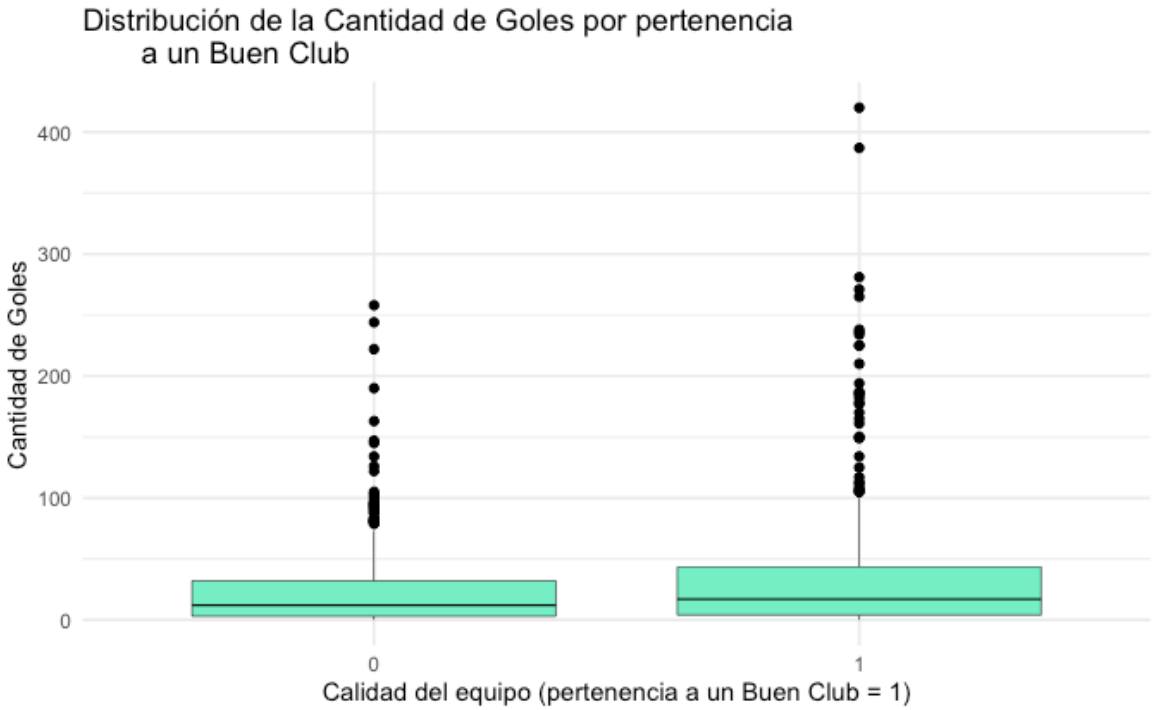


## Referencias


- Auspurg, K., & Brüderl, J. (2021). *Has the Credibility of the Social Sciences Been Credibly Destroyed? Reanalyzing the "Many Analysts, One Data Set" Project. Socius*, *7*. https://doi.org/10.1177/23780231211024421
- *Premier League 2011-12*. (2023, 28 de noviembre). Wikipedia, La enciclopedia libre. Fecha de consulta: diciembre 08, 2023 desde https://es.wikipedia.org/w/index.php?title=Premier_League_2011-12&oldid=155679020.
- *Premier League 2012-13*. (2023, 28 de noviembre). Wikipedia, La enciclopedia libre. Fecha de consulta: diciembre 08, 2023 desde https://es.wikipedia.org/w/index.php?title=Premier_League_2012-13&oldid=155679456.
- *Primera División de España 2011-12*. (2023, 29 de noviembre). Wikipedia, La enciclopedia libre. Fecha de consulta: diciembre 08, 2023 desde https://es.wikipedia.org/w/index.php?title=Primera_Divisi%C3%B3n_de_Espa%C3%B1a_2011-12&oldid=155700700.

- *Primera División de España 2012-13*. (2023, 29 de noviembre). Wikipedia, La enciclopedia libre. Fecha de consulta: diciembre 08, 2023 desde https://es.wikipedia.org/w/index.php?title=Primera_Divisi%C3%B3n_de_Espa%C3%B1a_2012-13&oldid=155700721.